

Escola Superior de Tecnologia e Gestão

Licenciatura em Engenharia Informática

Tecnologias de Computadores

Ano Letivo 2025/26

Trabalhos Laboratoriais de Introdução a Inteligência Artificial

Elaborado em: 2025/11/14

Guilherme Rodrigues a2020154390

Índice

List of Figures.....	2
1. Introdução.....	1
2. Fichas Laboratoriais	2
2.1. Análise de Dados Exploratória – Análise Descritiva.....	2
2.2. Análise de Dados Exploratória – Testes de Independência.....	16
2.3. Análise de Dados Exploratória – Testes Paramétricos e Não Paramétricos.....	29
2.4. Análise de Dados Exploratória -Python.....	40
2.5. Number Systems.....	57
2.6. Data Link Layer	57
3. Conclusão	57
4. References.....	58

List of Figures

FIGURA 1: MEDIDAS CENTRAIS	4
FIGURA 2: RESULTADO DAS MEDIDAS CENTRAIS.....	4
FIGURA 3: MEDIDAS DE DISPERSÃO	5
FIGURA 4: RESULTADO DAS MEDIDAS DE DISPERSÃO	5
FIGURA 5: MEDIDAS DE DISTRIBUIÇÃO	6
FIGURA 6: RESULTADO DAS MEDIDAS DE DISTRIBUIÇÃO	6
FIGURA 7: HISTOGRAMA DA VARÁVEL "SALARY"	7
FIGURA 8: SELEÇÃO DAS VARIÁVEIS DO HISTOGRAMA	8
FIGURA 9: HISTOGRAMA DO SALÁRIO PELO GÉNERO	9
FIGURA 10: ESCOLHA DA VARIÁVEL A ALTERAR	10
FIGURA 11: DEFINIÇÃO DA FAIXA SARIAL	10
FIGURA 12: DEFINIÇÃO DOS LABELS DA VARIÁVEL	11
FIGURA 13: SELEÇÃO DO GRÁFICO	11
FIGURA 14: SELEÇÃO DAS VARIÁVEIS ESCALAÃO DO SALÁRIO E AVALIAÇÃO DE DESEMPENHO	12
FIGURA 15: GRAFICO DE BARRAS DO AVALIAÇÃO DE DESEMPENHO × ESCALÕES DE SALÁRIO	12
FIGURA 16: SELEÇÃO DAS CONTAGENS	13
FIGURA 17: RESUMO DA TABELA E SELEÇÃO DAS VARIÁVEIS GENDERID E SALARY	13
FIGURA 18: TABELA RESULTANTE DE GÉNERO X SALÁRIO	13
FIGURA 19: SELEÇÃO DO TIPO DE BOXPLOT	14
FIGURA 20: SELEÇÃO DAS VARIÁVEIS	14
FIGURA 21: RESULTADO DO BOXPLOT	15
FIGURA 22: TABELA DE CONTINGÊNCIA	17
FIGURA 23: ESCOLHA DAS ESTATÍSTICAS	18
FIGURA 24: SELEÇÃO DA MOSTRAGEM DO QUE QUEREMOS VER	18
FIGURA 25: TABELA DE CONTINGÊNCIA GENDERID X PERFORMANCESCORE.....	19
FIGURA 26: TESTE QUI-QUADRADO	19
FIGURA 27: MEDIDAS DE ASSOCIAÇÃO	20
FIGURA 28: O MESMO TESTE MAS APENAS SE UMA CONDIÇÃO FOR SATISFEITA	20
FIGURA 29: DEFINIÇÃO DA NOSSA CONDIÇÃO	21
FIGURA 30: CROSSTAB RESULTANTE DOS CASOS FILTRADOS	21
FIGURA 31: TESTE DO QUI-QUADRADO RESULTANTE DOS CASOS FILTRADOS.....	22
FIGURA 32: MEDIDAS DE ASSOCIAÇÃO RESULTANTE DOS CASOS FILTRADOS.....	22
FIGURA 33: ADIÇÃO DE UMA LAYER A NOSSA CROSSTAB	23
FIGURA 34: TESTE QUI-QUADRADO COM LAYER	23
FIGURA 35: MEDIDAS DE ASSOCIAÇÃO COM LAYER	24
FIGURA 36: SELEÇÃO DAS VARIÁVEIS	26
FIGURA 37: TESTES DE NORMALIDADE	27
FIGURA 38: CORRELAÇÕES BIVARIATIVAS	27
FIGURA 39: RESULTADO DAS CORRELAÇÕES	27
FIGURA 40: ANÁLISE DE CORRELAÇÃO COM VARIÁVEIS ORDINAIS	28
FIGURA 41: RESULTADO	29
FIGURA 42: VERIFICAÇÃO DA NORMALIDADE DA NOSSA VARIÁVEL.....	30
FIGURA 43: SELEÇÃO DOS TESTES DE NORMALIDADE	30
FIGURA 44: RESULTADO DO NOSSO TESTE DE NORMALIDADE	30
FIGURA 45:SELEÇÃO DA VARIÁVEL NOVAMENTE	31
FIGURA 46: SELEÇÃO DOS TESTE	31

FIGURA 47: RESULTADO DOS NOSSOS TESTES DE SIMETRIS	32
FIGURA 48: REALIZAÇÃO DO TESTE T STUDENT	32
FIGURA 49: DEFINIÇÃO DOS GRUPOS	32
FIGURA 50: RESULTADO DO T TESTE	33
FIGURA 51: SELEÇÃO DAS VARIÁVEIS	33
FIGURA 52: SELEÇÃO DOS TESTES	34
FIGURA 53: RESULTADO DOS TESTES DE NORMALIDADE	34
FIGURA 54: REALIZAÇÃO DO ANOVA	35
FIGURA 55: SELEÇÃO DOS TESTES	35
FIGURA 56: RESULTADO DO TESTE DE LEVENE	36
FIGURA 57: ANOVA ONE WAY	36
FIGURA 58: SELEÇÃO DAS NOSSA VARÁVEIS	38
FIGURA 59: DEFINIÇÃO DOS GRUPOS	38
FIGURA 60: DEFINIÇÃO DAS VARIÁVEIS	39
FIGURA 61: SELEÇÃO DA FAIXA DE VALORES	39
FIGURA 62: RESULTADO DO TESTE	40
FIGURA 63: IMPORTAÇÃO DA BIBLIOTECA	40
FIGURA 64: LEITURA DO NOSSO CSV	40
FIGURA 65: OBTENÇÃO DAS 15 PRIMEIRAS LINHAS	40
FIGURA 66: CONTEÚDO DAS 15 PRIMEIRAS LINHAS	40
FIGURA 67: OBTENÇÃO DA DIMENSÃO DO NOSSO DATASET	41
FIGURA 68: DIMENSÃO DO NOSSO DATASET	41
FIGURA 69: REMOÇÃO DO HEADER	41
FIGURA 70: ANTES DA REMOÇÃO	41
FIGURA 71: DEPOIS DA REMOÇÃO	41
FIGURA 72: ADIÇÃO DOS NOVOS HEADERS	41
FIGURA 73: NOVOS HEADERS DO CSV	41
FIGURA 74: OBTENÇÃO DO NOME DAS COLUNAS	42
FIGURA 75: NOME DAS COLUNAS	42
FIGURA 76: DEFINIÇÃO DO NOME DA COLUNA 1	42
FIGURA 77: NOVO NOME DA COLUNA 1	42
FIGURA 78: TROCA DO NOME DA COLUNA INDEX	42
FIGURA 79: RESULTADO DA TROCA DE NOME	42
FIGURA 80: SUMÁRIO ESTATÍSTICO DESCRITIVO PARA CADA COLUNA	43
FIGURA 81: ESTATÍSTICA DESCRITIVA SOMENTE PARA VARIÁVEIS CATEGÓRICAS	44
FIGURA 82: RESULTADO DA ESTATÍSTICA DAS COLUNAS ESCOLHIDAS	45
FIGURA 83: MÁXIMO E MÍNIMO DA COLUNA 2	45
FIGURA 84: FREQUÊNCIA DE VALORES	45
FIGURA 85: UM DATAFRAME PARA CADA VALOR	46
FIGURA 86: HISTOGRAMA DOS VALORES DA COLUNA	46
FIGURA 87: CATEGORIAS EXISTENTES NA COLUNA 2.	47
FIGURA 88: BOXPLOT ERRADO	48
FIGURA 89: BOXPLOT CORRETO	49
FIGURA 90: NÚMERO DE NaN OBTIDOS	49
FIGURA 91: INFO DE CADA COLUNA	51
FIGURA 92: TIPOS DE CADA COLUNA	52
FIGURA 93: NOVO TIPO DA COLUNA 34	52
FIGURA 94: COLUNA NOVA	52

FIGURA 95: CRIAÇÃO DA NOVA COLUNA	53
FIGURA 96: COMPARAÇÃO COM A COLUNA ORIGINAL	53
FIGURA 97: COEFICIENTE DE CORRELAÇÃO	54
FIGURA 98: PAR MAIS RELACIONADO	55
FIGURA 99: PIVOT TABLE	55
FIGURA 100: PIVOT TABLE EM MODO GRÁFICO	56
FIGURA 101: PRESENTE A MÉDIA DA VARIÁVEL PARA CADA GRUPO	56
FIGURA 102: RESULTADO DOS TESTES	57

1. Introdução

Este relatório visa a realização das primeiras fichas de trabalhos disponibilizadas pelo professor. Estas fichas têm como objetivo aplicar técnicas fundamentais de análise exploratória de dados utilizando Python, recorrendo às bibliotecas Pandas, NumPy, Matplotlib, Seaborn e SciPy, assim como a exploração da aplicação IBM SPSS para análise desses mesmos dados. O objetivo desta última é perceber como é que diferentes variáveis, tais como, salários, género, departamentos, satisfação, desempenho, etc. se comportam, se têm relações entre elas ou não.

2. Fichas Laboratoriais

2.1. Análise de Dados Exploratória – Análise Descritiva

Software	Licença / Custo	Facilidade de Uso	Capacidades Estatísticas	Programação / Scripts	Integração / Extensibilidade	Público-alvo principal
SPSS (IBM)	Proprietário (pago, licenças anuais ou académicas)	Muito intuitivo, interface gráfica amigável	Completo: estatísticas descritivas, regressões, ANOVA, análise fatorial, séries temporais, etc.	Sintaxe própria (SPSS Syntax) — relativamente simples	Integra com Excel, SQL, R e Python	Académicos, investigadores, empresas
R	Gratuito (open source)	Curva de aprendizagem mais alta, interface baseada em código	Extremamente completo e expansível (pacotes CRAN, Bioconductor)	Linguagem própria (R) — altamente flexível	Integra com Python, SQL, Excel, SPSS, SAS	Estatísticos, cientistas de dados, investigadores
SAS	Proprietário (pago, licenças empresariais)	Interface menos moderna, mas estável	Muito robusto em análise preditiva e estatística avançada	Linguagem própria (SAS Programming Language)	Boa integração com bases de dados empresariais	Grandes empresas, setor financeiro, governo
Stata	Proprietário (licença paga, versão académica disponível)	Interface gráfica simples, mas também com linha de comandos	Muito usado em econometria e ciências sociais	Linguagem própria (Stata syntax)	Importa/exporta Excel, CSV, SQL	Pesquisadores, economistas, instituições académicas
PSPP	Gratuito (open source, clone do SPSS)	Interface quase idêntica ao SPSS	Cobertura parcial das funções do SPSS (estatísticas básicas e regressões simples)	Sintaxe compatível com SPSS	Limitada, mas abre ficheiros .sav do SPSS	Estudantes, utilizadores de baixo orçamento
JASP	Gratuito (open source, interface moderna)	Muito fácil e visual, semelhante ao SPSS	Baseado em R; oferece análises bayesianas e frequentistas	Scripts opcionais em R	Exporta para LaTeX, PDF, CSV	Ensino, psicologia, áreas sociais
Jamovi	Gratuito (open source, baseado em R)	Interface moderna e intuitiva	Análises estatísticas clássicas e avançadas, extensível com módulos	Baseado em R (permite scripts)	Integra com R e Python	Ensino, investigadores iniciantes

Em resumo:

- **SPSS** destaca-se pela usabilidade e popularidade no meio académico, mas é caro e tem limitações na automatização.
- **R** é o mais flexível e potente, ideal para quem domina programação.
- **SAS** é voltado para uso empresarial e análises de larga escala.
- **Stata** é forte em pesquisas sociais e econométricas.
- **PSPP**, **JASP** e **Jamovi** são ótimas alternativas gratuitas — especialmente para ensino ou quem quer evitar custos de licença.

Nas análises estatísticas, as variáveis representam as características observadas ou medidas nos elementos de uma amostra ou população.

Elas podem ser classificadas em categóricas (nominais e ordinais) e de escala (numéricas).

- **Variáveis Categóricas**

As variáveis categóricas são qualitativas, ou seja, expressam categorias ou atributos e não valores numéricos diretos.

Nominais: representam categorias sem ordem natural como por exemplo sexo (masculino/feminino), cor dos olhos, nacionalidade. Estas apenas permitem contagem e comparação de frequências.

Ordinais: representam categorias com uma hierarquia ou ordem lógica, mas sem intervalos numéricos definidos como por exemplo o nível de satisfação (baixo, médio, alto), grau de instrução. Estas permitem comparações de ordem (maior/menor), mas não cálculos matemáticos diretos.

- **Variáveis de Escala (Quantitativas)**

As variáveis de escala expressam valores numéricos mensuráveis, podendo ser manipuladas matematicamente.

Dividem-se em dois tipos principais:

- **Intervalares:** possuem diferenças significativas entre valores, mas sem zero absoluto por exemplo a temperatura em graus Celsius (0°C não significa ausência de temperatura).
- **Rácio (de razão):** possuem intervalos regulares e zero absoluto, o que permite todas as operações matemáticas por exemplo: altura, peso, rendimento, idade.

No SPSS, o campo Missing Values serve pra marcar valores especiais (como 0, 99, 9999, "NA", etc.) que representam ausência de dados reais

A janela de configuração de missing values é usada quando há códigos numéricos que significam "sem resposta", "não aplicável", "desconhecido", etc.

Exemplo:

- 9 = Não respondeu
- 99 = Não aplicável
- 999 = Dado ausente

Em seguida será apresentada e interpretada as estatísticas descritivas:

- a) medidas centrais
- b) medidas de dispersão
- c) medidas de distribuição

da variável de escala "Salary".

A variável Salary é de escala (Scale) porque representa valores numéricos contínuos, com uma unidade de medida real. Ela permite somar e subtrair (podendo ser calculadas médias, desvios, etc.), comparar diferenças (um salário de 60 000 é o dobro de 30 000), plicar todas as medidas estatísticas (centrais, dispersão e distribuição), ou seja é quantitativa contínua, ideal pra estatísticas descritivas.

Estas medidas mostram onde os dados se concentram dentro do foram marcados:

- Mean (Média)
- Median (Mediana)
- Mode (Moda)




Figura 1: Medidas Centrais

Estatísticas		
Salário Anual (USD)		
N	Válido	311
	Omisso	0
Média		69020,68
Mediana		62810,00
Modo		57815 ^a

Figura 2: Resultado das medidas centrais

Média: valor médio dos salários (69020,68 \$).

- É o salário médio dos 311 funcionários. Representa o valor “típico”, mas pode ser influenciado por salários muito altos..

Mediana: ponto central da distribuição (62 810,00 \$).

- É o salário central — metade ganha menos, metade ganha mais. Menos sensível a valores extremos.

Moda: salário mais frequente (57 815,00 \$).

- É o salário mais comum na amostra. Mostra o valor mais frequente pago na empresa.




Figura 3: Medidas de Dispersão

Estatísticas		
Salário Anual (USD)		
N	Válido	311
	Omisso	0
Erro Desvio		25156,637
Variância		632856381,61
Intervalo		204954
Mínimo		45046
Máximo		250000

Figura 4: Resultado das Medidas de Dispersão

Desvio Padrão: 25 156,64 \$

- Indica quanto os salários se afastam da média. Quanto maior, mais desigualdade salarial. Aqui, o valor é alto isso mostra que há grande variação entre salários.

Variância: 632 856 381,61 \$.

- É o desvio padrão ao quadrado. Mede a dispersão em escala ampliada; confirma que há alta variabilidade salarial.

Intervalo (Amplitude): 204 954 \$.

- É a diferença entre o salário mais alto e o mais baixo 250 000 \$ – 45 046 \$. Mostra o espaço total dos valores, ou seja, a diferença salarial é grande.

Mínimo: 45 046 \$

- O menor salário da empresa. Representa provavelmente cargos operacionais ou de base.

Máximo: 250 000 \$

- O maior salário registado, possivelmente de cargos executivos ou direção.




Figura 5: Medidas de Distribuição

Estatísticas		
Salário Anual (USD)		
N	Válido	311
	Omisso	0
Assimetria		3,306
Erro de assimetria padrão		,138
Curtose		15,452
Erro de Curtose padrão		,276

Figura 6: Resultado das Medidas de Distribuição

Assimetria (Skewness): 3,306 \$

- A distribuição é fortemente assimétrica à direita. Isso quer dizer que a maioria dos funcionários recebe salários abaixo da média, enquanto poucos indivíduos ganham muito mais, puxando a cauda da distribuição para o lado direito

Erro de Assimetria Padrão: 0,138 \$

- Serve pra calcular o z-score da assimetria ($3,306 \div 0,138 \approx 23,96$) muito maior que 2, logo a assimetria é estatisticamente significativa.

Curtose (Kurtosis): 15,452 \$

- Altamente leptocúrtica, ou seja, a distribuição é muito concentrada no centro e com caudas pesadas há poucos salários extremos, mas eles têm grande influência na média.

Erro de Curtose Padrão: 0,276 \$

- Também mostra que a curtose é estatisticamente significativa ($15,452 \div 0,276 \approx 56,0$).




Figura 7: Histograma da variável "Salary"

O histograma do salário apresenta uma distribuição assimétrica positiva e leptocúrtica, com grande concentração de valores baixos e poucos salários muito elevados.

A maioria dos funcionários ganha entre 45 000\$ e 80 000\$, enquanto poucos superam os 100 000\$.

Essa forma de distribuição reforça as conclusões anteriores, alta desigualdade salarial e forte influência dos valores extremos sobre a média.

Em seguida queremos cruzar uma variável numérica (de escala) com uma categórica, para comparar como a distribuição muda entre grupos.

Anteriormente já tinha sido usada a variável “Salary” como a variável de escala, agora é necessária a escolha de uma variável categórica que faça sentido pra explicar diferenças salariais.

Neste sentido escolheu-se a variável “GenderID” como categórica por permitir comparar a distribuição salarial entre homens e mulheres, analisando eventuais disparidades entre os grupos.




Figura 8: Seleção das variáveis do histograma




Figura 9: Histograma do salário pelo género

O histograma do salário anual em função do género evidencia que a maioria dos funcionários, tanto homens quanto mulheres, recebe salários entre 50 000\$ e 80 000\$. No entanto, o grupo masculino apresenta maior dispersão e maior frequência de salários elevados, chegando a valores superiores a 200 000\$. Já o grupo feminino mostra uma distribuição mais concentrada em faixas médias e quase nenhuma ocorrência de salários muito altos. Esses resultados indicam a presença de uma diferença salarial entre géneros, onde os homens têm maior variabilidade e maior incidência de rendimentos elevados, enquanto as mulheres estão mais concentradas em níveis salariais médios.

Através da recodificação da variável “Salary” criou-se a variável “Salary_R”, composta por três escalões salariais: “Salário Baixo” ($\leq 59\,999$ USD), “Salário Médio” (60 000–99 999 USD) e “Salário Alto” ($\geq 100\,000$ USD). Esta recodificação permite agrupar os valores de salário em classes homogêneas, facilitando a comparação entre categorias e a análise de padrões salariais por grupos (ex.: género, departamento, desempenho).




Figura 10: Escolha da variável a alterar

Em seguida definimos três faixas salariais, por exemplo:

1. 0 a 59 999 —> 1 (Salário Baixo)
2. 60 000 a 99 999 —> 2 (Salário Médio)
3. 100 000 a 250 000 —> 3 (Salário Alto)




Figura 11: Definição da faixa salarial




Figura 12: Definição dos Labels da variável

Em seguida faremos um gráfico que mostre como as categorias de uma variável se distribuem dentro de outra. Usaremos Escalões de Salário (Salary_R) por Gênero (GenderID).




Figura 13: Seleção do gráfico




Figura 14: Seleção das variáveis Escalaão do Salário e Avaliação de Desempenho




Figura 15: Grafico de Barras do Avaliação de Desempenho × Escalões de Salário

O gráfico demonstra uma relação positiva entre nível de desempenho e escalão salarial. Funcionários com melhor desempenho tendem a situar-se em faixas salariais mais altas, embora a maioria, mesmo com bom desempenho, permaneça no escalão médio. Os casos de baixo desempenho estão concentrados em salários baixos, o que confirma que o sistema de remuneração da empresa reflete parcialmente o mérito individual, ainda que não de forma totalmente proporcional.

Agora entraremos na parte das tabelas personalizadas (Custom Tables), onde o SPSS deixa cruzar uma variável de escala (numérica) com uma variável categórica e mostrar estatísticas descritivas (mínimo, máximo, média e desvio padrão) pra cada grupo.




Figura 16: Seleção das Contagens




Figura 17: Resumo da tabela e seleção das variáveis GenderID e Salary

		Salário Anual (USD)			
		Mínimo	Máximo	Média	Desvio padrão
Código de Género	Feminino	45046	250000	67787	25806
	Masculino	45115	178000	70629	24285

Figura 18: Tabela resultante de Género x Salário

Observa-se que o salário médio dos homens (70 629 \$) é ligeiramente superior ao das mulheres (67 787 \$), embora o valor máximo no grupo feminino (250 000 \$) seja substancialmente mais alto que o dos homens (178 000 \$). As mulheres apresentam um desvio padrão superior (25 806 USD), evidenciando maior variabilidade salarial dentro do grupo. Estes resultados sugerem uma leve diferença salarial média favorável aos homens, mas também a existência de casos pontuais de remuneração muito elevada entre as mulheres, possivelmente associadas a cargos de gestão ou direção.

Em seguida vamos criar um Boxplot da variável Salary (variável de escala) em função da variável GenderID (variável categórica). Este gráfico mostra como os salários se distribuem entre homens e mulheres, média, dispersão e outliers.




Figura 19: Seleção do tipo de Boxplot




Figura 20: Seleção das variáveis




Figura 21: Resultado do Boxplot

Cada caixa (box) representa um grupo (Feminino / Masculino).

Dentro da caixa:

- Linha no meio: a mediana (50% dos valores abaixo e 50% acima).
- Caixa: intervalo entre o 1º e o 3º quartil (50% dos valores centrais).
- “Bigodes” (whiskers): valores mais afastados mas ainda não extremos.
- Pontos isolados: outliers (valores muito altos ou baixos).

O gráfico evidencia que, apesar de os homens apresentarem uma mediana salarial ligeiramente superior, as mulheres apresentam uma maior amplitude e presença de valores extremos, refletindo uma maior dispersão dos salários dentro do grupo. Estes resultados reforçam a conclusão de que existe uma diferença salarial moderada entre géneros, com maior média entre os homens, mas com algumas mulheres a auferirem salários de topo que elevam o máximo do grupo feminino.

2.2. Análise de Dados Exploratória – Testes de Independência

O p-value (abreviação de probability value) ou “Sig.”, é a probabilidade de observar os resultados (ou mais extremos) se a hipótese nula (H_0) for verdadeira.

Em termos simples:

O p-value mede quão improvável é o resultado, assumindo que não existe diferença nem relação real entre as variáveis.

Antes de verificar o p-value, é necessário definir duas hipóteses:

1. H_0 (hipótese nula): não há diferença / não há relação
 - i. Ex: “O salário médio de homens e mulheres é igual.”
2. H_1 (hipótese alternativa): há diferença / há relação
 - i. Ex: “O salário médio de homens e mulheres é diferente.”

Depois no SPSS (ou qualquer software estatístico) fazemos um teste, por exemplo:

- Teste t de Student
- ANOVA
- Correlação de Pearson

E devolve o p-value (Sig.).

Valor de p	Interpretação	Decisão
$p \leq 0.05$	Resultado estatisticamente significativo	Rejeitar $H_0 \rightarrow$ há diferença / relação real
$p > 0.05$	Resultado não significativo	Aceitas $H_0 \rightarrow$ não há evidência de diferença

- Testes de Independência vs Testes de Associação

Tipo de Teste	Serve Para	Exemplo
Teste de Independência	Verificar se duas variáveis categóricas estão relacionadas	Género x Tipo de Contrato
Teste de Associação / Correlação	Ver se duas variáveis numéricas (ou uma numérica e outra ordinal) têm relação linear	Idade x Salário

Em resumo:

- Independência $\rightarrow$ “Uma variável depende da outra?”
- Associação $\rightarrow$ “Há relação entre os valores?”

Conceito	Tipo de Variável	Objetivo	Regra Prática
Qui-Quadrado (x2)	Categóricas	Ver se há Dependência	$P < 0.05 \rightarrow$ há relação
Fisher	Categóricas (não pequena)	Alternativa exata ao x2	$P < 0.05 \rightarrow$ há relação
Pearson (r)	Continua	Correlação linear	$R \rightarrow$ força e direção
Spearman (p)	Ordinais / não normal	Correlação monotónica	$P \rightarrow$ força e direção
Kendall (t)	Ordinais	Correlação robusta	$t \rightarrow$ força e direção
McNemar	Binária emparelhada	Mudança antes / depois	$P < 0.05 \rightarrow$ há relação
Coefficiente de Contingência (C)	Categóricas	Grau de associação	0 - 1 (maior $\rightarrow$ mais associação)

Construiremos uma tabela de contingência (crosstabs) completa usando medidas de independência e associação para averiguar o tipo de relação existente entre duas variáveis categóricas (GenderID e PeerformanceScore)




Figura 22: Tabela de Contingência




Figura 23: Escolha das estatísticas




Figura 24: Seleção da mostragem do que queremos ver

Tabulação cruzada Código de Género * Avaliação de Desempenho

Código de Género			Avaliação de Desempenho				Total
			Excede as expectativas	Cumprir totalmente as expectativas	Needs Improvement	Plano de Melhoria de Desempenho	
Código de Género	Feminino	Contagem	20	142	9	5	176
		Contagem Esperada	20,9	137,5	10,2	7,4	176,0
		% em Código de Género	11,4%	80,7%	5,1%	2,8%	100,0%
		% em Avaliação de Desempenho	54,1%	58,4%	50,0%	38,5%	56,6%
		% do Total	6,4%	45,7%	2,9%	1,6%	56,6%
	Masculino	Contagem	17	101	9	8	135
		Contagem Esperada	16,1	105,5	7,8	5,6	135,0
		% em Código de Género	12,6%	74,8%	6,7%	5,9%	100,0%
		% em Avaliação de Desempenho	45,9%	41,6%	50,0%	61,5%	43,4%
		% do Total	5,5%	32,5%	2,9%	2,6%	43,4%
Total		Contagem	37	243	18	13	311
		Contagem Esperada	37,0	243,0	18,0	13,0	311,0
		% em Código de Género	11,9%	78,1%	5,8%	4,2%	100,0%
		% em Avaliação de Desempenho	100,0%	100,0%	100,0%	100,0%	100,0%
		% do Total	11,9%	78,1%	5,8%	4,2%	100,0%

Figura 25: Tabela de Contingência GenderID x PerformanceScore

Conseguimos perceber que as mulheres são a maioria em todos os níveis de desempenho, mas isso reflete só o fato de haver mais mulheres no total (176 vs 135).

As proporções entre categorias são parecidas entre géneros → não há diferenças claras visuais.

Testes qui-quadrado

	Valor	df	Significância Assintótica (Bilateral)
Qui-quadrado de Pearson	2,491 ^a	3	,477
Razão de verossimilhança	2,472	3	,480
N de Casos Válidos	311		

a. 0 células (0,0%) esperavam uma contagem menor que 5. A contagem mínima esperada é 5,64.

Figura 26: Teste Qui-Quadrado

O valor de Sig. ($p = 0,477$) é muito maior que 0.05, logo não há evidência de relação estatística entre o género e o desempenho.

As diferenças nas proporções parecem ser aleatórias.

A hipótese nula (H_0) de independência é mantida.

Em palavras simples o género não parece influenciar a avaliação de desempenho de forma estatisticamente significativa. Homens e mulheres têm distribuições de desempenho parecidas.

Medidas Simétricas		Valor	Significância Aproximada
Nominal por Nominal	Fi	,090	,477
	V de Cramer	,090	,477
	Coefficiente de contingência	,089	,477
N de Casos Válidos		311	

Figura 27: Medidas de Associação

Todos os valores estão bem próximos de 0 o que indica uma associação praticamente inexistente.

Mesmo se fosse significativa ($p < 0.05$), uma associação de 0.09 seria muito fraca.

Podemos concluir que não existe diferença estatisticamente significativa no tipo de desempenho entre homens e mulheres. Tanto homens quanto mulheres têm proporções semelhantes nos níveis “Excede as expectativas”, “Cumpre totalmente”, etc.

Em seguida vamos repetir os testes anteriores, mas desta vez considerando um subconjunto à escolha das observações do dataset que verifique uma determinada condição.




Figura 28: O mesmo teste mas apenas se uma condição for satisfeita




Figura 29: Definição da nossa condição

A condição escolhida foi apenas empregados ativos (Termd = 0).

Tabulação cruzada Código de Género * Avaliação de Desempenho

			Avaliação de Desempenho				Total
			Excede as expectativas	Cumpe totalmente as expectativas	Needs Improvement	Plano de Melhoria de Desempenho	
Código de Género	Feminino	Contagem	16	93	4	3	116
		Contagem Esperada	16,3	90,8	4,5	4,5	116,0
		% em Código de Género	13,8%	80,2%	3,4%	2,6%	100,0%
		% em Avaliação de Desempenho	55,2%	57,4%	50,0%	37,5%	56,0%
		% do Total	7,7%	44,9%	1,9%	1,4%	56,0%
	Masculino	Contagem	13	69	4	5	91
		Contagem Esperada	12,7	71,2	3,5	3,5	91,0
		% em Código de Género	14,3%	75,8%	4,4%	5,5%	100,0%
		% em Avaliação de Desempenho	44,8%	42,6%	50,0%	62,5%	44,0%
		% do Total	6,3%	33,3%	1,9%	2,4%	44,0%
Total		Contagem	29	162	8	8	207
		Contagem Esperada	29,0	162,0	8,0	8,0	207,0
		% em Código de Género	14,0%	78,3%	3,9%	3,9%	100,0%
		% em Avaliação de Desempenho	100,0%	100,0%	100,0%	100,0%	100,0%
		% do Total	14,0%	78,3%	3,9%	3,9%	100,0%

Figura 30: CrossTab resultante dos casos filtrados

A distribuição é muito semelhante entre os dois géneros, ambos têm maior concentração em “Cumpe totalmente as expectativas”. Pequenas diferenças (ex: homens têm um pouco mais no “Plano de Melhoria”), mas nada muito expressivo. Aqui podemos suspeitar que não há diferença estatisticamente significativa entre homens e mulheres.

Testes qui-quadrado

	Valor	df	Significância Assintótica (Bilateral)
Qui-quadrado de Pearson	1,367 ^a	3	,713
Razão de verossimilhança	1,358	3	,715
N de Casos Válidos	207		

a. 4 células (50,0%) esperavam uma contagem menor que 5. A contagem mínima esperada é 3,52.

Figura 31: Teste do Qui-Quadrado resultante dos casos filtrados

O p-value = 0,713 > 0,05, ou seja, não é significativo.

Isto significa que não há evidência de dependência entre as variáveis.

Em linguagem simples podemos dizer que o desempenho dos empregados não depende do gênero, mesmo entre os que continuam empregados.

Medidas Simétricas

		Valor	Significância Aproximada
Nominal por Nominal	Fi	,081	,713
	V de Cramer	,081	,713
	Coefficiente de contingência	,081	,713
N de Casos Válidos		207	

Figura 32: Medidas de Associação resultante dos casos filtrados

Esses valores vão de 0 (sem relação) até 1 (relação perfeita).

Como estão bem próximos de 0, significa que a relação é praticamente inexistente.

Mesmo se fosse significativa, a associação seria muito fraca.

Para concluir ao analisarmos apenas os funcionários ativos (Termd = 0), o teste do Qui-Quadrado indicou ausência de relação significativa entre o gênero e a avaliação de desempenho (p = 0,713). As medidas de associação (V de Cramer = 0,081) confirmam que a relação é muito fraca. Assim, podemos afirmar que, mesmo entre os empregados atualmente ativos, o desempenho não varia de forma significativa entre homens e mulheres.

Em seguida realizaremos o teste de independência (Qui-Quadrado), mas com uma terceira variável categórica a “fazer camadas” (Layer), ou seja, iremos comparar o mesmo teste em subgrupos diferentes da amostra.

Na prática já testamos, anteriormente, Código de Gênero × Avaliação de Desempenho e verificamos que não há relação significativa (p = 0,713). Agora vamos repetir o mesmo teste, mas dividido por uma terceira variável categórica, no caso Estado Civil.




Figura 33: Adição de uma layer a nossa crosstab

As estatísticas e a nossa visualização seguem iguais a crosstab anterior.

Testes qui-quadrado					
Estado Civil Detalhado		Valor	df	Significância Assintótica (Bilateral)	Sig exata (2 lados)
0	Qui-quadrado de Pearson	,265 ^b	3	,967	
	Razão de verossimilhança	,264	3	,967	
	N de Casos Válidos	137			
Solteiro	Qui-quadrado de Pearson	5,233 ^c	3	,156	
	Razão de verossimilhança	5,430	3	,143	
	N de Casos Válidos	124			
Casado	Qui-quadrado de Pearson	3,168 ^d	2	,205	
	Razão de verossimilhança	3,936	2	,140	
	N de Casos Válidos	30			
Divorciado	Qui-quadrado de Pearson	1,037 ^e	2	,595	
	Razão de verossimilhança	1,189	2	,552	
	N de Casos Válidos	12			
Viuvo	Qui-quadrado de Pearson	1,143 ^f	1	,285	
	Correção de continuidade ^g	,000	1	1,000	
	Razão de verossimilhança	1,530	1	,216	
	Teste Exato de Fisher				1,000
	N de Casos Válidos	8			,500
Total	Qui-quadrado de Pearson	2,491 ^a	3	,477	
	Razão de verossimilhança	2,472	3	,480	
	N de Casos Válidos	311			

- a. 0 células (0,0%) esperavam uma contagem menor que 5. A contagem mínima esperada é 5,64.
b. 4 células (50,0%) esperavam uma contagem menor que 5. A contagem mínima esperada é 2,72.
c. 5 células (62,5%) esperavam uma contagem menor que 5. A contagem mínima esperada é 2,52.
d. 4 células (66,7%) esperavam uma contagem menor que 5. A contagem mínima esperada é ,93.
e. 5 células (83,3%) esperavam uma contagem menor que 5. A contagem mínima esperada é ,25.
f. 4 células (100,0%) esperavam uma contagem menor que 5. A contagem mínima esperada é ,50.
g. Computado apenas para uma tabela 2x2

Figura 34: Teste Qui-Quadrado com layer

O teste Qui-Quadrado não mostrou associação significativa entre gênero e avaliação de desempenho ($p > 0,05$) em nenhum estado civil, indicando independência entre as variáveis em todos os grupos analisados.

Medidas Simétricas				
Estado Civil Detalhado			Valor	Significância Aproximada
0	Nominal por Nominal	Fi	,044	,967
		V de Cramer	,044	,967
		Coeficiente de contingência	,044	,967
	N de Casos Válidos		137	
Solteiro	Nominal por Nominal	Fi	,205	,156
		V de Cramer	,205	,156
		Coeficiente de contingência	,201	,156
	N de Casos Válidos		124	
Casado	Nominal por Nominal	Fi	,325	,205
		V de Cramer	,325	,205
		Coeficiente de contingência	,309	,205
	N de Casos Válidos		30	
Divorciado	Nominal por Nominal	Fi	,294	,595
		V de Cramer	,294	,595
		Coeficiente de contingência	,282	,595
	N de Casos Válidos		12	
Viuvo	Nominal por Nominal	Fi	-,378	,285
		V de Cramer	,378	,285
		Coeficiente de contingência	,354	,285
	N de Casos Válidos		8	
Total	Nominal por Nominal	Fi	,090	,477
		V de Cramer	,090	,477
		Coeficiente de contingência	,089	,477
	N de Casos Válidos		311	

Figura 35: Medidas de Associação com layer

Mesmo quando dividimos por estado civil, o gênero não tem impacto significativo na avaliação de desempenho. As relações são fracas ou inexistentes e o estado civil não muda essa conclusão.

Características	Correlação de Pearson	Correlação de Spearman
Tipo de Variável	Quantitativas (escala ou razão)	Ordinais ou quantitativas não normais
Pressupostos	Requer distribuição normal e relação linear	Não requer normalidade apenas relação monotónica
O que mede	Relação linear entre duas variáveis	Relação monotónica (aumenta/diminui mas não precisa ser linear)
Base Matemática	Calcula a covariância dividida pelos desvios padrão	Calcula o ranking das variáveis e mede a correlação entre os postos
Símbolo	R	P (rho)
Intervalo de valores	-1 a 1	-1 a 1
Interpretação	Mesmo sentido: quanto mais próximo de mais ou menos -> correlação forte	Mesmo sentido: mais ou menos 1 é igual a correlação perfeita, 0 é igual a nenhuma correlação

Interpretação de intensidade da correlação

Valor de r ou p	Interpretação
0,00 – 0,19	Muito Fraca
0,20 – 0,39	Fraca
0,40 – 0,59	Moderada
0,60 – 0,79	Forte
0,80 – 1,00	Muito Forte





Figura 36: Seleção das variáveis



Testes de Normalidade						
	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Estatística	gl	Sig.	Estatística	gl	Sig.
Salário Anual (USD)	,213	311	<,001	,685	311	<,001
Dias de Atraso nos Últimos 30 Dias	,520	311	<,001	,357	311	<,001

a. Correlação de Significância de Lilliefors

Figura 37: Testes de Normalidade

Aqui, todos os p-values são menores que 0,001, portanto, para ambas as variáveis (Salário e Dias de Atraso):

- Rejeitamos a hipótese de normalidade.
- Ou seja, nenhuma delas segue uma distribuição normal.

Bivariate Correlations

Variables:

- Salário Anual (USD) [Salary]
- Satisfação do Funcionário (0-5) [EmpSatisfaction]

Correlation Coefficients

☒ Pearson ☐ Kendall's tau-b ☐ Spearman

Test of Significance

☒ Two-tailed ☐ One-tailed

☒ Flag significant correlations ☐ Show only the lower triangle ☒ Show diagonal

OK Paste Reset Cancel Help

Figura 38: Correlações Bivariativas

Correlações			
		Salário Anual (USD)	Satisfação do Funcionário (0-5)
Salário Anual (USD)	Correlação de Pearson	1	,063
	Sig. (2 extremidades)		,270
	N	311	311
Satisfação do Funcionário (0-5)	Correlação de Pearson	,063	1
	Sig. (2 extremidades)	,270	
	N	311	311

Figura 39: Resultado das correlações

O valor de Sig. (2 extremidades) é o p-value do teste de hipótese:

- H_0 : não há correlação entre as variáveis ($r = 0$)
- H_1 : existe correlação ($r \neq 0$)

Como $p = 0,270 > 0,05$, não há evidência estatística de correlação significativa.

Portanto mantém-se a hipótese nula, as variáveis são independentes.

O sinal de r (positivo ou negativo) indica o sentido da relação:

- $r > 0$: quando o salário aumenta, a satisfação tende a aumentar
- $r < 0$: quando o salário aumenta, a satisfação tende a diminuir

Aqui r é positivo (+0,063), mas tão pequeno que é estatisticamente irrelevante, há uma leve tendência de quem ganha mais estar mais satisfeito, mas não significativa.

Por fim no conjunto de dados fornecido, as principais variáveis ordinais são:

- PerfScoreID → Código de desempenho (ex: "Needs Improvement", "Fully Meets", etc.)
- EmpSatisfaction (0-5) → Grau de satisfação do funcionário
- EngagementSurvey (0-5) → Nível de envolvimento no trabalho
- SpecialProjectsCount → nº de projetos especiais pode ser interpretado ordinalmente
- TermReason e EmpStatusID também são ordinais em algumas análises, mas dependem da codificação.

Resumindo: as duas principais boas para o próximo teste são: EmpSatisfaction e EngagementSurvey porque são escala de 0 a 5 (ordinal e comparável).




Figura 40: Análise de correlação com variáveis ordinais

Correlações			Satisfação do Funcionário (0- 5)	Resultado da Pesquisa de Engajamento
rô de Spearman	Satisfação do Funcionário (0-5)	Coefficiente de Correlação	1,000	,124 [*]
		Sig. (2 extremidades)	.	,028
		N	311	311
	Resultado da Pesquisa de Engajamento	Coefficiente de Correlação	,124 [*]	1,000
		Sig. (2 extremidades)	,028	.
		N	311	311

Figura 41: Resultado

Aqui, $p = 0,028$, portanto:

A correlação é estatisticamente significativa ao nível de 5%. Isto significa que há evidência estatística de que existe uma relação entre as variáveis, mesmo que seja fraca.

2.3. Análise de Dados Exploratória – Testes Paramétricos e Não Paramétricos

Para verificar os pressupostos da normalidade, analisam-se:

1. Testes estatísticos de normalidade (Shapiro-Wilk e Kolmogorov-Smirnov);
2. Medidas de distribuição (assimetria e curtose);
3. Análise visual (histograma e gráfico Q-Q);
4. E, se a amostra for grande, aplica-se o Teorema do Limite Central, que garante normalidade aproximada das médias.

Em seguida queremos saber se duas populações (definidas por uma variável categórica com dois grupos) têm médias diferentes numa variável de escala.

Iremos usar o exemplo prático: “O salário médio é diferente entre homens e mulheres?”

Variável de escala (quantitativa): Salary (Salário Anual em USD)

Variável categórica (com dois valores): Vamos usar uma que já exista (GenderID, com 0 = Feminino, 1 = Masculino).

Começamos por verificar a normalidade, antes do teste t, necessitamos de confirmar se a variável de escala (Salary) é aproximadamente normal em cada grupo.




Figura 42: Verificação da normalidade da nossa variável




Figura 43: Seleção dos testes de normalidade

Testes de Normalidade							
		Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Código de Género	Estatística	gl	Sig.	Estatística	gl	Sig.
Salário Anual (USD)	Feminino	,248	176	<,001	,605	176	<,001
	Masculino	,180	135	<,001	,781	135	<,001

Figura 44: Resultado do nosso teste de normalidade

O valor de Sig é menor que 0,05.

Os testes de normalidade (Shapiro-Wilk e Kolmogorov-Smirnov) são sensíveis a amostras grandes ($N > 30$), ou seja, enormalmente darão $p < 0,05$, mesmo quando a distribuição é “normal o suficiente” para testes paramétricos.

Neste caso temos 311 casos pelo que poderemos tentar verificar pela Skewness e Kurtosis e ver se se enquadram dentro de limites aceitáveis.




Figura 45: Seleção da variável novamente




Figura 46: seleção dos teste

Estatísticas Descritivas							
	N	Média	Desvio padrão	Assimetria		Curtose	
	Estatística	Estatística	Estatística	Estatística	Erro Padrão	Estatística	Erro Padrão
Salário Anual (USD)	311	69020,68	25156,637	3,306	,138	15,452	,276
N válido (de lista)	311						

Figura 47: Resultado dos nossos testes de Simetris

A normalidade das variáveis foi analisada através das medidas de assimetria (Skewness) e curtose (Kurtosis).

A variável “Salário Anual (USD)” apresentou valores de Skewness = 3,306 e Kurtosis = 15,452, indicando uma distribuição positivamente assimétrica e leptocúrtica.

Apesar da violação dos pressupostos de normalidade, o tamanho amostral ($N = 311$) é suficientemente elevado para que, pelo Teorema do Limite Central, se possa recorrer a testes paramétricos como o t de Student, considerados robustos a desvios moderados da normalidade.




Figura 48: Realização do teste t student




Figura 49: Definição dos grupos

Teste de amostras independentes											
Teste de Levene para igualdade de variâncias				teste-t para Igualdade de Médias							
		Z	Sig.	t	df	Significância		Diferença média	Erro de diferença padrão	95% Intervalo de Confiança da Diferença	
						Unilateral p	Bilateral p			Inferior	Superior
Salário Anual (USD)	Variâncias iguais assumidas	1,041	,308	-,988	309	,162	,324	-2842,673	2878,238	-8506,099	2820,753
	Variâncias iguais não assumidas			-,996	296,390	,160	,320	-2842,673	2855,243	-8461,792	2776,447

Figura 50: Resultado do t teste

O teste de Levene ($p = 0,308$) indicou que as variâncias entre os grupos podem ser consideradas iguais, pelo que foi utilizada a linha “Variâncias iguais assumidas” na análise do teste t de Student.

O resultado do teste t ($t(309) = -0,988$, $p = 0,324$) demonstra que não existe diferença estatisticamente significativa entre as médias dos salários anuais (USD) dos dois grupos considerados.

A diferença média observada (-2842,67 USD) não é suficiente para rejeitar a hipótese nula de igualdade de médias, visto que o intervalo de confiança a 95% [-8506,10 ; 2820,75] inclui o valor 0.

Assim, conclui-se que não há evidência de diferença significativa nas médias salariais entre os dois grupos analisados.

Vamos considerar uma variável de escala, e uma variável categórica com três ou mais valores.

Iremos utilizar a mesma variável de escala (quantitativa): Salary (Salário Anual em USD).

A variável categórica será “Department”.

Começamos por verificar a normalidade dos grupos assim como anteriormente.




Figura 51: Seleção das variáveis




Figura 52: Seleção dos testes

Testes de Normalidade^b

		Kolmogorov-Smirnov ^a			Shapiro-Wilk		
Nome do Departamento		Estatística	gl	Sig.	Estatística	gl	Sig.
Salário Anual (USD)	Admin Of	,298	9	,021	,841	9	,059
	IT/IS	,144	50	,011	,892	50	<,001
	Producti	,133	209	<,001	,722	209	<,001
	Sales	,370	31	<,001	,396	31	<,001
	Software	,144	11	,200 [*]	,970	11	,882

Figura 53: Resultado dos testes de normalidade

Neste caso o que nos interessa é a coluna Sig do Shapiro-Wilk, pois é o mais fiável para $N < 50$. Posto isto verificamos que a normalidade não é cumprida em quase todos os grupos, exceto “Admin Of” e “Software”.

Mesmo sem normalidade perfeita, o ANOVA é robusto a desvios moderados da normalidade se as amostras forem grandes (≥ 30 por grupo, o teu caso em “Production” e “IT/IS”), e as variâncias forem semelhantes (testadas depois pelo Levene).

Para tamanhos amostrais superiores a 30, a distribuição das médias tende a normalidade, permitindo o uso de testes paramétricos como o ANOVA.




Figura 54: Realização do ANOVA




Figura 55: Seleção dos testes

Testes de homogeneidade de variâncias

		Estatística de Levene	df1	df2	Sig.
Salário Anual (USD)	Com base em média	15,001	4	305	<,001
	Com base em mediana	12,449	4	305	<,001
	Com base em mediana e com gl ajustado	12,449	4	148,271	<,001
	Com base em média aparada	13,673	4	305	<,001

Figura 56: Resultado do teste de Levene

O teste de Levene ($p < 0,001$) indica que as variâncias salariais não são homogêneas entre os departamentos, violando o pressuposto de homogeneidade.

Ainda assim, considerando o tamanho da amostra e a robustez do ANOVA a desvios deste pressuposto, o teste foi mantido, complementado posteriormente com testes Post Hoc apropriados (Games-Howell).

ANOVA

Salário Anual (USD)					
	Soma dos Quadrados	df	Quadrado Médio	Z	Sig.
Entre Grupos	96642389150	5	19328477830	59,222	<,001
Nos grupos	99543089149	305	326370784,10		
Total	1,962E+11	310			

Figura 57: ANOVA one way

O teste ANOVA one-way revelou diferenças estatisticamente significativas nas médias dos salários anuais entre os diferentes departamentos, $F(5, 305) = 59,22$, $p < 0,001$.

Isto significa que pelo menos um dos departamentos apresenta uma média salarial significativamente diferente dos restantes.

Os testes não paramétricos são testes estatísticos que não exigem pressupostos fortes sobre a distribuição dos dados.

- Principais motivos para recorrer a testes não paramétricos

Enquanto os testes paramétricos (tipo t de Student ou ANOVA) assumem que os dados seguem uma distribuição normal e têm variâncias homogêneas, os não paramétricos funcionam mesmo quando essas condições falham.

Motivo	Explicação
Ausência de normalidade	Quando os dados não seguem uma distribuição normal (ex: teste Shapiro-Wilk com $p < 0.05$), os testes paramétricos deixam de ser adequados.
Dados ordinais ou nominais	Quando as variáveis são ordinais (ex: níveis de satisfação 1-5) ou nominais (ex: género, estado civil), não faz sentido calcular médias — logo, usamos testes baseados em ranks (posições) em vez de médias.
Amostras pequenas ($N < 30$)	Em amostras pequenas, o Teorema do Limite Central não se aplica e a normalidade não pode ser assumida. Os testes não paramétricos são mais fiáveis.
Presença de outliers/extremos	Quando há valores muito discrepantes, os testes paramétricos são distorcidos; os não paramétricos, baseados em posições (ranks), são muito mais resistentes.
Variâncias desiguais	Se as variâncias são muito diferentes entre grupos (violação do teste de Levene), os não paramétricos tornam-se mais adequados.

Vamos usarum teste não paramétrico para verificar se a mediana da variável de escala é estatisticamente diferente entre os dois subconjuntos delimitados por uma variável categórica considerada.

Vamos usar as varáveis de escala (quantitativa): Salary e categórica com dois grupos GenderID (Masculino / Feminino).




Figura 58: Seleção das nossas variáveis




Figura 59: Definição dos grupos

teste de Mann-Whitney U foi aplicado para avaliar se a mediana dos salários anuais (USD) difere entre os dois grupos considerados.

O resultado ($U = 10869,5$; $Z = -1,286$; $p = 0,199$) indica que não existem diferenças estatisticamente significativas entre as medianas salariais dos grupos.

Assim, não se rejeita a hipótese nula de igualdade das medianas, concluindo-se que as distribuições salariais são semelhantes entre os dois grupos analisados.

O teste Mann-Whitney foi escolhido por ser uma alternativa não paramétrica ao teste t, adequada a dados que não seguem distribuição normal.

O teste de Kruskal-Wallis é o equivalente não paramétrico ao ANOVA One-Way. Serve para comparar três ou mais grupos independentes, avaliando se as medianas diferem significativamente.




Figura 60: Definição das variáveis




Figura 61: Seleção da faixa de valores

Estatísticas de teste^{a,b}

	Salário Anual (USD)
H de Kruskal-Wallis	97,454
df	4
Significância Sig.	<,001

Figura 62: Resultado do teste

O teste de Kruskal-Wallis ($H(4) = 97,454$; $p < 0,001$) indica que existe uma diferença estatisticamente significativa nas medianas dos salários anuais entre os diferentes departamentos.

Isso significa que pelo menos um dos departamentos tem salários significativamente diferentes dos restantes.

2.4. Análise de Dados Exploratória -Python

- **Aquisição de Dados**

Começamos por importar a biblioteca Pandas.

```
import pandas as pd
```

Figura 63: Importação da biblioteca

Usamos a função “**read_csv**” para efetuar a leitura do conteúdo do nosso CSV.

```
# 1 ler o CSV
df = pd.read_csv("Dataset_python.csv")
```

Figura 64: leitura do nosso csv

Depois usamos a função “**print**” em conjunto com a função “**head**” e passamos o número “15” para dentro desta ultima para obter apenas as 15 primeiras linhas.

```
# 2 ver as 15 primeiras linhas
print(df.head(15))
```

Figura 65: Obtenção das 15 primeiras linhas

	Employee Name	EmpID	MarriedID	MaritalStatusID	GenderID	...	EmpSatisfaction	SpecialProjectsCount	LastPerformanceReview_Date	DaysLateLast30	Absences
0	Adinolfi, Wilson K	10026	0	0	1	...	5	0	1/17/2019	0	1
1	Ait Sidi, Karthikeyan	10084	1	1	1	...	3	6	2/24/2016	0	17
2	Akinkuolie, Sarah	10196	1	1	0	...	3	0	5/15/2012	0	3
3	Alagbe,Trina	10088	1	1	0	...	5	0	1/3/2019	0	15
4	Anderson, Carol	10069	0	2	0	...	4	0	2/1/2016	0	2
5	Anderson, Linda	10002	0	0	0	...	5	0	1/7/2019	0	15
6	Andreola, Colby	10194	0	0	0	...	3	4	1/2/2019	0	19
7	Athwal, Sam	10062	0	4	1	...	4	0	2/25/2019	0	19
8	Bachiochi, Linda	10114	0	0	0	...	3	0	1/25/2019	0	4
9	Bacong, Alejandro	10250	0	2	1	...	5	6	2/18/2019	0	16
10	Baczinski, Rachael	10252	1	1	0	...	4	0	1/30/2016	0	12
11	Barbara, Thomas	10242	1	1	1	...	3	0	5/6/2016	0	15
12	Barbosa, Hector	10012	0	2	1	...	4	5	2/25/2019	0	9
13	Barone, Francesco A	10265	0	0	1	...	4	0	2/14/2019	0	7
14	Barton, Nader	10066	0	2	1	...	5	0	3/2/2017	0	1

Figura 66: Conteúdo das 15 primeiras linhas

Em seguida obtemos a dimensão do nosso dataset recorrendo a função “shape”.

```
# 3 Obter a dimensão do dataset
print(df.shape)
```

Figura 67: Obtenção da dimensão do nosso dataset

```
[15 rows x 36 columns]
(311, 36)
```

Figura 68: Dimensão do nosso dataset

A nossa primeira linha do dataset contém os headers, vamos re correr a função “to_csv” para remover essa primeira linha, passamos os argumentos “index=False” e “header=False” para remover o desejado.

```
# 4 remover a primeira linha do dataset
df.to_csv("Dataset_python.csv", index=False, header=False)
print(df.head(2))
```

Figura 69: Remoção do header

```
[rodrigues@Dragnit-archlinux Inteligencia-Artificial]$ /usr/sbin/python3.13 /home/rodrigues/escola/IA/Inteligencia-Artificial/Ficha_Python_1.py
Employee_Name EmpID MarriedID MaritalStatusID GenderID EmpStatusID DeptID ... PerformanceScore EngagementSurvey EmpSatisfaction SpecialProjectsCount LastPerformanceReview_Date DaysLateLast30 Absences
0 Adinolfi, Wilson K 10026 0 1 1 5 4 0.2 62506 0.3 19 ... Active Production Michael Albert 22.0 LinkedIn Exceeds 4.6 5.1 0.4 1/17/2019 0.5 1.2
1 Ait Sidi, Karthikeyan 10084 1 1 1 5 3 3 0 104437 1 27 ... Voluntarily Terminated IT/IS Simon Roup 4.0 Indeed Fully Meets 4.96 3 6 2/24/2016 0 17
[2 rows x 36 columns]
```

Figura 70: Antes da Remoção

```
[rodrigues@Dragnit-archlinux Inteligencia-Artificial]$ /usr/sbin/python3.13 /home/rodrigues/escola/IA/Inteligencia-Artificial/Ficha_Python_1.py
coluna1,coluna2,coluna3,coluna4,coluna5,coluna6,coluna7,coluna8,coluna9,coluna10,coluna11,coluna12,coluna13,coluna14,coluna15,coluna16,coluna17,coluna18,coluna19,coluna20,coluna21,coluna22,coluna23,coluna24,coluna25,coluna26,coluna27,coluna28,coluna29,coluna30,coluna31,coluna32,coluna33,coluna34,coluna35,coluna36
0 Adinolfi, Wilson K 10026 0 0.1 1 1.1 5 4 0.2 62506 0.3 19 ... Active Production Michael Albert 22.0 LinkedIn Exceeds 4.6 5.1 0.4 1/17/2019 0.5 1.2
1 Ait Sidi, Karthikeyan 10084 1 1 1 5 3 3 0 104437 1 27 ... Voluntarily Terminated IT/IS Simon Roup 4.0 Indeed Fully Meets 4.96 3 6 2/24/2016 0 17
2 Akinkuolie, Sarah 10196 1 1 0 5 5 3 0 64955 1 20 ... Voluntarily Terminated Production Kissy Sullivan 20.0 LinkedIn Fully Meets 3.02 3 0 5/15/2012 0 3
```

Figura 71: Depois da Remoção

Em seguida vamos colocar novos headers no nosso dataset. Começamos por contar quantas colunas existem usando a função “shape”, depois criamos os nomes dos nosso headers automaticamente utilizando o numero de colunas obtido anteriormente e por ultimo adicionamos esses headers no nosso csv com a função “to_csv”

```
# 5 adicionar headers novos
n = df.shape[1]
df.columns = [f"coluna{i+1}" for i in range(n)]
df.to_csv("Dataset_python.csv", index=False)
print(df.head(2))
```

Figura 72: Adição dos novos headers

```
coluna1,coluna2,coluna3,coluna4,coluna5,coluna6,coluna7,coluna8,coluna9,coluna10,coluna11,coluna12,coluna13,coluna14,coluna15,coluna16,coluna17,coluna18,coluna19,coluna20,coluna21,coluna22,coluna23,coluna24,coluna25,coluna26,coluna27,coluna28,coluna29,coluna30,coluna31,coluna32,coluna33,coluna34,coluna35,coluna36
"Ait Sidi, Karthikeyan",10084,1,1,1,5,3,3,0,104437,1,27,Sr. DBA,MA,2148,05/05/75,M,Married,US Citizen,No,White,3/30/2015,6/16/2016,career change,Voluntarily Terminated,IT/IS,Simon
```

Figura 73: Novos headers do CSV

Depois conseguimos ver o nome das nossas colunas usando a função “**columns**”

```
# 6 apresentar o nome das colunas
print(df.columns)
```

Figura 74: Obter o nome das colunas

```
Index(['coluna1', 'coluna2', 'coluna3', 'coluna4', 'coluna5', 'coluna6',
      'coluna7', 'coluna8', 'coluna9', 'coluna10', 'coluna11', 'coluna12',
      'coluna13', 'coluna14', 'coluna15', 'coluna16', 'coluna17', 'coluna18',
      'coluna19', 'coluna20', 'coluna21', 'coluna22', 'coluna23', 'coluna24',
      'coluna25', 'coluna26', 'coluna27', 'coluna28', 'coluna29', 'coluna30',
      'coluna31', 'coluna32', 'coluna33', 'coluna34', 'coluna35', 'coluna36'],
      dtype='object')
```

Figura 75: Nome das colunas

Vamos trocar o nome de uma coluna a nossa escolha, no caso a primeira coluna terá o nome de “**Nome**”, para isso usamos a função “**rename**”, depois definimos o nome novo da coluna e verificamos.

```
# 7 trocar o nome de uma coluna a escolha
df.rename(columns={'coluna1': 'Nome'}, inplace=True)
print(df.head(2))
```

Figura 76: Definição do nome da coluna1

	Nome	coluna2	coluna3
0	Ait Sidi, Karthikeyan	10084	1
1	Akinkuolie, Sarah	10196	1

Figura 77: Novo nome da coluna1

É possível trocar o nome da primeira coluna de Index para Indice usando a função “**index.name**”.

```
# 8 trocar o nome da primeira coluna de index para indice
df.index.name = 'Indice'
print(df.head())
```

Figura 78: Troca do nome da coluna Index

Indice	
0	Ait Sidi, Karthikeyan
1	Akinkuolie, Sarah
2	Alagbe, Trina
3	Anderson, Carol
4	Anderson, Linda

Figura 79: Resultado da troca de nome

- **Estatística Descritiva**

Em seguida pretendemos obter um sumário da estatística descritiva para cada coluna (média, desvio padrão, quartis), incluindo as colunas do tipo "object". Para isso usamos a função "**describe()**" com o argumento "**include='all'**" para incluir toda a informação do dataset.

	coluna1	coluna2	coluna3	coluna4	\
count	310	310.000000	310.00000	310.000000	
unique	310	NaN	NaN	NaN	
top	Ait Sidi, Karthikeyan	NaN	NaN	NaN	
freq	1	NaN	NaN	NaN	
mean	NaN	10156.419355	0.40000	0.812903	
std	NaN	89.762460	0.49069	0.943635	
min	NaN	10001.000000	0.00000	0.000000	
25%	NaN	10079.250000	0.00000	0.000000	
50%	NaN	10156.500000	0.00000	1.000000	
75%	NaN	10233.750000	1.00000	1.000000	
max	NaN	10311.000000	1.00000	4.000000	

	coluna5	coluna6	coluna7	coluna8	coluna9	\
count	310.000000	310.000000	310.000000	310.000000	310.000000	
unique	NaN	NaN	NaN	NaN	NaN	
top	NaN	NaN	NaN	NaN	NaN	
freq	NaN	NaN	NaN	NaN	NaN	
mean	0.432258	2.396774	4.609677	2.974194	0.093548	
std	0.496191	1.795533	1.085013	0.585127	0.291670	
min	0.000000	1.000000	1.000000	1.000000	0.000000	
25%	0.000000	1.000000	5.000000	3.000000	0.000000	
50%	0.000000	1.000000	5.000000	3.000000	0.000000	
75%	1.000000	5.000000	5.000000	3.000000	0.000000	
max	1.000000	5.000000	6.000000	4.000000	1.000000	

	coluna10	...	coluna27	coluna28	coluna29	coluna30	\
count	310.000000	...	310	302.000000	310	310	
unique	NaN	...	21	NaN	9	4	
top	NaN	...	Kissy Sullivan	NaN	Indeed	Fully Meets	
freq	NaN	...	22	NaN	87	243	
mean	69041.700000	...	NaN	14.546358	NaN	NaN	
std	25194.576153	...	NaN	8.080338	NaN	NaN	
min	45046.000000	...	NaN	1.000000	NaN	NaN	
25%	55463.250000	...	NaN	10.000000	NaN	NaN	
50%	62860.000000	...	NaN	14.500000	NaN	NaN	
75%	72071.000000	...	NaN	19.000000	NaN	NaN	
max	250000.000000	...	NaN	39.000000	NaN	NaN	

	coluna31	coluna32	coluna33	coluna34	coluna35	coluna36
count	310.000000	310.000000	310.000000	310	310.000000	310.000000
unique	NaN	NaN	NaN	137	NaN	NaN
top	NaN	NaN	NaN	1/14/2019	NaN	NaN
freq	NaN	NaN	NaN	18	NaN	NaN
mean	4.108419	3.887097	1.222581	NaN	0.416129	10.267742
std	0.790722	0.908515	2.352195	NaN	1.296397	5.838378
min	1.120000	1.000000	0.000000	NaN	0.000000	1.000000
25%	3.690000	3.000000	0.000000	NaN	0.000000	5.000000
50%	4.280000	4.000000	0.000000	NaN	0.000000	10.000000
75%	4.700000	5.000000	0.000000	NaN	0.000000	15.000000
max	5.000000	5.000000	8.000000	NaN	6.000000	20.000000

Figura 80: sumário estatístico descritivo para cada coluna

Variáveis Categóricas (tipo object)

As colunas de tipo categórico apresentam as seguintes estatísticas principais:

- **count** — número de registos não nulos existentes na coluna. No dataset, é comum observar-se um valor de 310, indicando que todos os registos possuem dados nessa coluna.
- **unique** — número de valores distintos.

Quando **unique** é igual a **count**, isso indica que todos os valores são diferentes (ex.: nomes de pessoas ou identificadores únicos).

- **top** — valor mais frequente presente na coluna.
- **freq** — número de ocorrências do valor mais frequente.

Estas métricas permitem identificar:

- Colunas onde todos os valores são distintos (possíveis IDs ou nomes próprios).
- Colunas que representam categorias repetidas (ex.: avaliações, estados, classificações), geralmente com um conjunto reduzido de valores únicos.
- Colunas que contêm datas representadas como texto, sendo aconselhável a sua conversão para o tipo **datetime**.

Variáveis Categóricas (tipo **object**)

As colunas de tipo categórico apresentam as seguintes estatísticas principais:

- **count** — número de registos não nulos existentes na coluna. No dataset, é comum observar-se um valor de 310, indicando que todos os registos possuem dados nessa coluna.
- **unique** — número de valores distintos.

Quando **unique** é igual a **count**, isso indica que todos os valores são diferentes (ex.: nomes de pessoas ou identificadores únicos).

- **top** — valor mais frequente presente na coluna.
- **freq** — número de ocorrências do valor mais frequente.

A seguir queremos obter um sumário da estatística descritiva somente para variáveis categóricas. Para isso voltamos a utilizar a função “**describe()**” com o argumento “**include=['object']**”.

		coluna1		coluna13	coluna14	coluna16	\
count		310		310	310	310	
unique		310		32	28	306	
top	Ait Sidi, Karthikeyan	Production Technician I		MA	09/09/65		
freq	1	136		275	2		
	coluna17	coluna18	coluna19	coluna20	coluna21	coluna22	coluna23 \
count	310	310	310	310	310	310	104
unique	2	5	3	4	6	101	96
top	F	Single	US Citizen	No	White	1/10/2011	9/24/2012
freq	176	136	294	281	186	14	2
	coluna24	coluna25		coluna26		coluna27	\
count	310	310		310		310	
unique	18	3		6		21	
top	N/A-StillEmployed	Active	Production	Kissy Sullivan			
freq	206	206	208	22			
	coluna29	coluna30	coluna34				
count	310	310	310				
unique	9	4	137				
top	Indeed	Fully Meets	1/14/2019				
freq	87	243	18				

Figura 81: estatística descritiva somente para variáveis categóricas

A seguir vamos querer um sumário da estatística descritiva somente para uma coluna (à escolha), respeitante a uma variável de escala. As colunas escolhidas foram a 2 e a 3 e pra esse efeito voltamos a utilizar a função **“describe()”** com o conteúdo de apenas das duas colunas.

```
count    coluna3    coluna2
mean      0.40000    10156.419355
std       0.49069     89.762460
min       0.00000    10001.000000
25%       0.00000    10079.250000
50%       0.00000    10156.500000
75%       1.00000    10233.750000
max       1.00000    10311.000000
```

Figura 82: Resultado da estatística das colunas escolhidas

Em seguida queremos obter os valores máximos e mínimos da coluna2 usada anteriormente, para este fim usamos as funções **“max()”** e **“min()”**.

```
10311
10001
```

Figura 83: Maximo e minino da coluna 2

Apresentaremos a frequência de cada um dos valores possíveis de uma coluna (à escolha), respeitante a uma variável categórica, com o uso da função **“value_counts()”**.

```
coluna2
10084    1
10196    1
10088    1
10069    1
10002    1
.
10135    1
10301    1
10010    1
10043    1
10271    1
Name: count, Length: 310, dtype: int64
```

Figura 84: frequencia de valores

Criaremos um dataframe contendo cada um dos valores possíveis da coluna da alínea anterior, para este fim usamos duas funções em conjunto `"value_counts()"` e `"to_frame"`.

	count
coluna2	
10084	1
10196	1
10088	1
10069	1
10002	1
...	...
10135	1
10301	1
10010	1
10043	1
10271	1

Figura 85: um dataframe para cada valor

Por fim vamos apresentar graficamente o histograma da coluna anterior. Usamos a função `"hist"` para escolher a coluna, em seguida `"xlabel"` para escolher o label do eixo dos x, depois `"ylabel"` para escolher o label do eixo dos y, `"title"` para escolher o titulo do nosso histograma e por fim `"show"` para mostrar o histograma.




Figura 86: Histograma dos valores da coluna

Apresentar as categorias existentes na coluna2.

```
array([10084, 10196, 10088, 10069, 10002, 10194, 10062, 10114, 10250,
       10252, 10242, 10012, 10265, 10066, 10061, 10023, 10055, 10245,
       10277, 10046, 10226, 10003, 10294, 10267, 10199, 10081, 10175,
       10177, 10238, 10184, 10203, 10188, 10107, 10181, 10150, 10001,
       10085, 10115, 10082, 10040, 10067, 10108, 10210, 10154, 10200,
       10240, 10168, 10220, 10275, 10269, 10029, 10261, 10292, 10282,
       10019, 10094, 10193, 10132, 10083, 10099, 10212, 10056, 10143,
       10311, 10070, 10155, 10306, 10100, 10310, 10197, 10276, 10304,
       10284, 10207, 10133, 10028, 10006, 10105, 10211, 10064, 10247,
       10235, 10299, 10280, 10296, 10290, 10263, 10136, 10189, 10308,
       10309, 10049, 10093, 10163, 10305, 10015, 10080, 10258, 10273,
       10111, 10257, 10159, 10122, 10142, 10283, 10018, 10255, 10246,
       10228, 10243, 10031, 10300, 10101, 10237, 10051, 10218, 10256,
       10098, 10059, 10234, 10109, 10125, 10074, 10097, 10007, 10129,
       10075, 10167, 10195, 10112, 10272, 10182, 10248, 10201, 10214,
       10160, 10289, 10139, 10227, 10236, 10009, 10060, 10034, 10156,
       10036, 10138, 10244, 10192, 10231, 10089, 10166, 10170, 10208,
       10176, 10165, 10113, 10092, 10106, 10052, 10038, 10249, 10232,
       10087, 10134, 10251, 10103, 10017, 10186, 10137, 10008, 10096,
       10035, 10057, 10004, 10191, 10219, 10077, 10073, 10279, 10110,
       10053, 10076, 10145, 10202, 10128, 10068, 10116, 10298, 10213,
       10288, 10025, 10223, 10151, 10254, 10120, 10216, 10079, 10215,
       10185, 10063, 10037, 10042, 10206, 10104, 10303, 10078, 10121,
       10021, 10281, 10041, 10148, 10005, 10259, 10286, 10297, 10171,
       10032, 10130, 10217, 10016, 10050, 10164, 10124, 10187, 10225,
       10262, 10131, 10239, 10152, 10140, 10058, 10011, 10230, 10224,
       10047, 10285, 10020, 10162, 10149, 10086, 10054, 10065, 10198,
       10222, 10126, 10295, 10260, 10233, 10229, 10169, 10071, 10179,
       10091, 10178, 10039, 10095, 10027, 10291, 10153, 10157, 10119,
       10180, 10302, 10090, 10030, 10278, 10307, 10147, 10266, 10241,
       10158, 10117, 10209, 10024, 10173, 10221, 10146, 10161, 10141,
       10268, 10123, 10013, 10287, 10044, 10102, 10270, 10045, 10205,
       10014, 10144, 10253, 10118, 10022, 10183, 10190, 10274, 10293,
       10172, 10127, 10072, 10048, 10204, 10264, 10033, 10174, 10135,
       10301, 10010, 10043, 10271])
```

Figura 87: categorias existentes na coluna2.

Para a análise gráfica através de **boxplots** foi necessário criar categorias artificiais, uma vez que a coluna originalmente utilizada como variável categórica apresentava **310** valores distintos, todos únicos. Esta característica **inviabiliza** a construção de um **boxplot interpretável**, dado que este tipo de gráfico exige a existência de grupos com múltiplas observações para representar de forma adequada a mediana, quartis e possíveis outliers. Assim, a abordagem adotada consistiu na criação de categorias derivadas da variável numérica, permitindo agrupar os dados em classes **homogéneas**. Desta forma, o **boxplot** torna-se estatisticamente válido e visualmente interpretável, garantindo uma análise comparativa coerente entre grupos e preservando a utilidade do gráfico.




Figura 88: Boxplot errado

Tentativa de boxplot usando uma coluna com valores únicos (nomes). Como cada categoria tem apenas um valor, o boxplot não pode ser construído corretamente, resultando apenas em traços isolados e um gráfico não informativo.




Figura 89: Boxplot correto

Boxplot correto, criado após agrupar os valores da coluna2 em quatro categorias (baixo, médio, alto, muito alto). Aqui cada grupo contém múltiplas observações, permitindo calcular estatísticas como mediana, quartis e dispersão. É um boxplot válido e interpretável.

- **Missing Values**

Para introduzir valores em falta de forma controlada, selecionou-se uma coluna correspondente a uma variável de escala e substituiu-se um dos seus valores por **NaN**. Para isso utilizou-se a função “**replace(10050, np.nan)**”, para substituir o valor **10050** por **NaN**.

Em seguida queremos obter o número de missing values presentes na coluna escolhida anteriormente. Usamos a função “**isnull()**” para obter os valores negativos e a função “**value_counts()**” para contar o número de valores negativos obtidos.

```
coluna2
False    309
True       1
Name: count, dtype: int64
```

Figura 90: Número de NaN obtidos

Os missing values podem ser tratados de várias formas, dependendo da quantidade de dados em falta e do tipo de variável.

Método	Descrição
Remover linhas	Apagar registos com missing values quando são poucos.
Remover colunas	Eliminar colunas com muitos dados em falta.
Imputar pela média	Substituir NaN pela média (variáveis numéricas).
Imputar pela mediana	Substituir pela mediana quando há outliers.
Imputar pela moda	Usado para variáveis categóricas.
Valor constante	Substituir por um valor fixo (0, -1, "Desconhecido").
Imputação por modelos	Previsão via regressão, KNN ou MICE.
Coluna indicadora	Criar coluna extra que assinala onde havia NaN.
Manter NaN	Útil em análises exploratórias ou antes do pré-processamento.

Em seguida vamos substituir os “**missing values**” presentes na coluna anterior e substituir pela média da própria coluna. Começamos por calcular a média com a função “**mean()**” e em seguida “**replace()**” para substituir o valor pretendido.

Por fim vamos remover os valores **NaN** da nossa tabela. A função “**dropna()**” remove registos (linhas) ou variáveis (colunas) que contenham valores em falta, isto permite limpar o dataset quando esses valores são indesejados ou quando representam uma percentagem reduzida dos dados.

A função “**reset_index()**” reordena os índices do DataFrame após operações como remoção de linhas, garantindo que a numeração volta a ser sequencial e consistente.

- **Normalização**

Tipo de Dados	Nome (dtype)	Descrição	Exemplos de Utilização
Inteiro	int64, int32, int16	Valores numéricos sem casas decimais.	Contagens, IDs numéricos, quantidades.
Decimal (float)	float63, float32	Números reais com casas decimais.	Médias, preços, medidas contínuas.
Booleano	bool	Valores lógicas: True/False.	Flags, condições, indicadores binários.
Texto/Genérico	object	Strings ou mistura de tipos não numéricos.	Nomes, códigos, datas como texto.
String (moderno)	string	Tipo de texto otimizado pelo Pandas.	Texto puro, descrições, etiquetas.
Catagórico	category	Variáveis com um conjunto limitado de categorias.	Estado civil, departamentos, rótulos.
Data/Tempo	datetime64	Datas ou timestamps otimizados.	Datas de registo, períodos, séries temporais.
Duração	timedelta64	Intervalo de tempo.	Diferenças entre datas, duração de eventos.

Vamos obter os tipos de dados de cada colu na e vamos obter tambem a sua informação com ajuda das funções “dtypes” e “info()”

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 310 entries, 0 to 309
Data columns (total 37 columns):
#   Column      Non-Null Count  Dtype
---  -
0   coluna1     310 non-null    object
1   coluna2     310 non-null    float64
2   coluna3     310 non-null    int64
3   coluna4     310 non-null    int64
4   coluna5     310 non-null    int64
5   coluna6     310 non-null    int64
6   coluna7     310 non-null    int64
7   coluna8     310 non-null    int64
8   coluna9     310 non-null    int64
9   coluna10    310 non-null    int64
10  coluna11    310 non-null    int64
11  coluna12    310 non-null    int64
12  coluna13    310 non-null    object
13  coluna14    310 non-null    object
14  coluna15    310 non-null    int64
15  coluna16    310 non-null    object
16  coluna17    310 non-null    object
17  coluna18    310 non-null    object
18  coluna19    310 non-null    object
19  coluna20    310 non-null    object
20  coluna21    310 non-null    object
21  coluna22    310 non-null    object
22  coluna23    104 non-null    object
23  coluna24    310 non-null    object
24  coluna25    310 non-null    object
25  coluna26    310 non-null    object
26  coluna27    310 non-null    object
27  coluna28    302 non-null    float64
28  coluna29    310 non-null    object
29  coluna30    310 non-null    object
30  coluna31    310 non-null    float64
31  coluna32    310 non-null    int64
32  coluna33    310 non-null    int64
33  coluna34    310 non-null    object
34  coluna35    310 non-null    int64
35  coluna36    310 non-null    int64
36  grupo      310 non-null    category
dtypes: category(1), float64(3), int64(15), object(18)
memory usage: 87.8+ KB
```

Figura 91: Info de cada coluna

```
(coluna1      object
coluna2      float64
coluna3      int64
coluna4      int64
coluna5      int64
coluna6      int64
coluna7      int64
coluna8      int64
coluna9      int64
coluna10     int64
coluna11     int64
coluna12     int64
coluna13     object
coluna14     object
coluna15     int64
coluna16     object
coluna17     object
coluna18     object
coluna19     object
coluna20     object
coluna21     object
coluna22     object
coluna23     object
coluna24     object
coluna25     object
coluna26     object
coluna27     object
coluna28     float64
coluna29     object
coluna30     object
coluna31     float64
coluna32     int64
coluna33     int64
coluna34     object
coluna35     int64
coluna36     int64
grupo        category
dtype: object,
None)
```

Figura 92: tipos de cada coluna

Vamos converter a coluna34 para **DATETIME**. Usamos a função **"to_datetime()"** para converter a coluna desejada e depois usamos a função **"dtype()"** para ver o tipo da coluna.

```
datetime64[ns]
```

Figura 93: novo tipo da coluna34

Vamos a seguir normalizar a coluna2, respeitante a uma variável de escala, através da criação de uma nova coluna que resulte da primeira, mas cujos valores variem entre 0 e 1.

- **f["coluna2"].max()** calcula o valor máximo presente na coluna2.
- **df["coluna2"] / df["coluna2"].max()** Cada valor da coluna2 é dividido pelo valor máximo.
- O maior valor torna-se 1.
- Todos os restantes valores ficam entre 0 e 1, mantendo a mesma proporção relativa.

```
0      0.977985
1      0.988847
2      0.978373
3      0.976530
4      0.970032
Name: coluna2_norm, dtype: float64
```

Figura 94: coluna nova

- **Binning**

Vamos criar uma nova coluna que resulte da divisão da coluna2, que respeite a uma variável de escala, em três categorias "Baixa", "Media", "Elevada".

A função "**np.linspace(..., 4)**"

- Divide o intervalo [mínimo → máximo] da coluna em 3 partes iguais (porque 4 pontos de corte criam 3 grupos).

A função **group_names**

- São as categorias que vão substituir os valores numéricos: Baixa, Media e Elevada

A função "**pd.cut()**"

- Mete cada valor da coluna2 dentro de uma das 3 categorias.

A função "**df["coluna2_cat"]**" cria a nova coluna:

	coluna2	coluna2_cat
0	10084	Baixa
1	10196	Media
2	10088	Baixa
3	10069	Baixa
4	10002	Baixa
5	10194	Media
6	10062	Baixa
7	10114	Media
8	10250	Elevada
9	10252	Elevada

Figura 95: Criação da nova coluna

Compararemos a coluna criada anteriormente com a coluna que a originou.

	coluna2_cat	coluna2
0	Baixa	10084
1	Media	10196
2	Baixa	10088
3	Baixa	10069
4	Baixa	10002

Figura 96: Comparação com a coluna original

- Estatística Inferencial

Queremos obter o coeficiente de correlação entre as diferentes colunas (features) numéricas do dataset usando a função `"df.corr()"`.

Se apenas usarmos esta função só será calculada a correlação entre colunas numéricas. As colunas object são automaticamente ignoradas. Para ver apenas o que nos interessa utilizamos a função `"numeric_only=True"` evita warnings e força só as numéricas.

	coluna2	coluna3	coluna4	coluna5	coluna6	coluna7
coluna2	1.000000	0.044452	-0.048090	0.041475	0.070427	0.109480
coluna3	0.044452	1.000000	0.162150	-0.021267	0.083748	-0.119139
coluna4	-0.048090	0.162150	1.000000	-0.027157	0.112717	0.013785
coluna5	0.041475	-0.021267	-0.027157	1.000000	-0.029669	-0.040255
coluna6	0.070427	0.083748	0.112717	-0.029669	1.000000	0.089719
coluna7	0.109480	-0.119139	0.013785	-0.040255	0.089719	1.000000
coluna8	-0.688911	-0.054103	0.049839	-0.061774	-0.067231	-0.087282
coluna9	0.045469	-0.013567	0.040282	0.032749	0.188436	-0.129675
coluna10	-0.116939	0.025514	-0.071104	0.057179	-0.111683	-0.447973
coluna11	0.089454	0.075307	0.097595	-0.013168	0.947973	0.066813
coluna12	-0.034993	-0.026456	0.022917	-0.083080	0.222350	0.029904
coluna15	0.025677	-0.041912	0.009877	0.049652	-0.151376	0.290434
coluna28	0.095122	-0.091729	0.025779	-0.046856	0.237173	0.550022
coluna31	-0.589124	-0.089698	0.035038	-0.038670	0.025904	-0.095741
coluna32	-0.142081	-0.123410	0.005480	-0.049326	0.013663	0.030659
coluna33	-0.046334	0.060003	-0.052620	0.089213	-0.168100	-0.785003
coluna35	0.495775	0.002035	-0.097523	0.081697	0.077601	0.125049
coluna36	-0.032907	0.092405	0.014409	0.001254	0.088313	0.055377

Figura 97: coeficiente de correlação

Para identificar as duas variáveis numéricas mais correlacionadas foi calculada a **matriz de correlação** do dataset utilizando a função `"df.corr(numeric_only=True)"`. Em seguida, esta matriz foi reorganizada com `"unstack()"` e filtrada de forma a remover as autocorrelações. O par de variáveis com maior correlação absoluta foi obtido através de `"idxmax()"`.

Após identificadas as duas features mais relacionadas, foi criado um **scatterplot** com `"sns.regplot()"`, permitindo visualizar a relação linear entre ambas. Este gráfico confirma graficamente a tendência observada na matriz de correlação e facilita a interpretação da força e direção da relação entre as duas variáveis.




Figura 98: Par mais relacionado

Criamos uma **pivot table** com base numa **variável de escala** e **duas variáveis categóricas**. Para tal, selecionaram-se três colunas: **duas categóricas**, usadas como dimensões de **agrupamento**, e uma **variável numérica**, sobre a qual foi calculada a **média**. Após o agrupamento com “**groupby()**”, os resultados foram reorganizados através da função “**pivot()**”, produzindo uma tabela onde cada linha representa uma categoria da primeira variável, cada coluna representa uma categoria da segunda, e cada célula contém o valor médio da variável numérica correspondente. Esta representação facilita a comparação direta entre grupos e permite identificar padrões ou diferenças relevantes entre categorias.

coluna30	Exceeds	Fully Meets	Needs Improvement	\
coluna29				
CareerBuilder	10020.500000	10131.058824	10291.500000	
Diversity Job Fair	10016.166667	10186.111111	10289.250000	
Employee Referral	10019.600000	10146.600000	NaN	
Google Search	10016.500000	10157.325581	10287.333333	
Indeed	10018.500000	10165.075758	10287.000000	
LinkedIn	10021.125000	10170.360656	10286.666667	
On-line Web application	NaN	10066.000000	NaN	
Other	NaN	10174.000000	NaN	
Website	10017.000000	10095.900000	NaN	
coluna30	PIP			
coluna29				
CareerBuilder	NaN			
Diversity Job Fair	10300.000000			
Employee Referral	10305.000000			
Google Search	10301.000000			
Indeed	10305.000000			
LinkedIn	10303.333333			
On-line Web application	NaN			
Other	NaN			
Website	10305.500000			

Figura 99: pivot table




Figura 100: Pivot table em modo gráfico

Em seguida vamos apresentar a média da variável de escala anterior para cada grupo de umas das variáveis categóricas anteriores. Para isso, foi criado um subconjunto do DataFrame contendo apenas essas duas variáveis e, de seguida, aplicou-se a função “**groupby()**” com agregação através da média. O resultado permite comparar o valor médio da variável numérica entre os diferentes grupos da variável categórica.

	coluna29	coluna2
0	CareerBuilder	10149.347826
1	Diversity Job Fair	10169.103448
2	Employee Referral	10131.225806
3	Google Search	10162.469388
4	Indeed	10158.505747
5	LinkedIn	10164.413333
6	On-line Web application	10066.000000
7	Other	10174.000000
8	Website	10122.076923


Figura 101: presente a média da variável para cada grupo

Foi realizado um teste **One-Way ANOVA** com o objetivo de avaliar se existiam diferenças estatisticamente significativas entre as médias da **variável de escala** selecionada (**coluna2**) de acordo com os diferentes grupos da **variável categórica** (**coluna29**).

O teste resultou num valor **F = 0.8749** e num valor **p = 0.5379**.

Dado que o valor p é superior ao nível de significância habitual (**$\alpha = 0.05$**), não existe evidência estatística para rejeitar a hipótese nula de igualdade de médias entre os grupos.

Assim, conclui-se que não há diferenças significativas na variável de escala entre os diferentes grupos definidos pela variável categórica analisada.



```
F = 0.8749822933508861
p = 0.5378898650212661
```

Figura 102: Resultado dos testes

2.5. Number Systems

2.6. Data Link Layer

xxx

3. Conclusão

A realização desta ficha permitiu desenvolver um trabalho de análise exploratória de dados, abrangendo desde a limpeza inicial do dataset até à aplicação de testes estatísticos inferenciais.

Foi possível identificar e corrigir problemas relacionados com tipos de dados, valores em falta e necessidade de normalização, garantindo a preparação adequada do dataset para análises posteriores.

Por fim, o teste One-Way ANOVA demonstrou que, no caso analisado, não existem diferenças estatisticamente significativas entre os grupos considerados.

No conjunto, estas etapas reforçam a importância das técnicas de pré-processamento, visualização e análise estatística na compreensão aprofundada de dados reais.



**Escola Superior
de Tecnologia
e Gestão**

Politécnico de Coimbra

Insert the main title here

4. References