

Estatística Descritiva

Estuda uma amostra em vez de todos os dados

Mean → Média

Median → Mediana

Mode → Moda

Medidas Centrais

Medidas de Dispersão

Desvio Padrão

A quantidade de variância de um conjunto de valores. Um valor baixo significa que os valores andam perto da média.


$$\sigma = \sqrt{\frac{\sum (x_i - \mu)^2}{N}}$$

σ = population standard deviation

N = the size of the population


x_i = each value from the population

μ = the population mean




Dados são considerados normais se:

- 68% estiver entre 1σ
- 95% estiver entre 2σ
- 99,7 estiver entre 3σ



Quartil

Divide os dados em 4 partes




Skewness (assimetria)

Mede a assimetria da distribuição normal.

negativa : A distribuição está concentrada na **direita**

positiva : A distribuição está concentrada na **esquerda**




O valor da skewness dá entre **-1,96** e **1,96**

Kurtosis

Mede a altura da distribuição de dados,

Uma distribuição normal é mesokurtica



$$\beta > 3$$

$$\beta = 3$$

$$\beta < 3$$

Testes de Independência

Os testes de independência testam se existe uma **associação** entre 2 ou mais variáveis **categóricas**.

Pearson's Chi Squared

→ Determina se existe uma associação entre variáveis **categóricas** (independente ou relacionada).

→ Teste Não Paramétrico

→ Usado para determinar se existe diferença significativa entre as variáveis

→ Este algoritmo resulta numa tabela de frequências.

(**cross table**)

		
	Female	Male
Without graduation	6	7
College	13	16
Bachelor's degree	16	15
Master's degree	8	11
Total	43	49

(expected frequencios)

	 Female	 Male
Without graduation	6.08	6.92
College	13.55	15.45
Bachelor's degree	14.49	16.51
Master's degree	8.88	10.12
Total	43	49

Cálculo do p-value

$$\chi^2 = \sum_{k=1}^n \frac{(O_k - E_k)^2}{E_k} \rightarrow \chi^2 = \frac{(6 - 6.08)^2}{6.08} + \frac{(7 - 6.92)^2}{6.92} + \frac{(13 - 13.55)^2}{13.55} + \dots = 0.504$$

Se o sig (p-value) for $<$ que 0,05
rejeita-se hipótese nula.

$> 0,05 \rightarrow$ Independentes (Hipótese Nula)

$< 0,05 \rightarrow$ Dependentes

Resíduos Ajustados (Z)

Estes testes são usados quando as variáveis são independentes. É a diferença entre o valor observado e o esperado.

$> 1,96 \rightarrow$ Associação Positiva (Observado maior que esperado)

$< -1,96 \rightarrow$ Associação Negativa (Observado menor que esperado)

$-1,96 \dots 1,96 \rightarrow$ Sem associação

Pressupostos

Um pressuposto é uma condição que diz se o p-value é confiável. É confiável quando:

- > não há mais que 20% de células com valor esperado < 5

- > nenhuma célula com valor esperado < 1

Medidas de Associação

Medem a intensidade da relação entre variáveis. Só são usados com variáveis estatisticamente relacionadas.

nominal x nominal	[	Phi
Ordinal (se a ordem não interessa)		- V Cramer
		coeficiente de Contingência

ordinal x ordinal	[	Tau B de Kendall
(quando a ordem interessa)		Tau C de Kendall

nominal x intervalo	[	Eta
		Eta ²

Medida	Cálculo
Phi	$\Phi = \sqrt{\frac{\chi^2}{n}}$
V de Cramer	$V = \sqrt{\frac{\chi^2}{n(q-1)}}$
Coeficiente de Contingência	$C = \sqrt{\frac{\chi^2}{\chi^2 + n}}$

} Crosstables 2x2

} valor entre $0 \leq V \leq 1$

} valores entre $0 \leq C < 1$

Os resultados dos coeficientes variam entre 0 e 1.

0,9 → muito forte

0,7 ... 0,9 → forte

0,5 ... 0,7 → moderada

0,3 ... 0,5 → fraca

0 ... 0,3 → desprezavel

Medidas de Correlação

A intensidade da relação linear entre 2 variáveis,

As relações são medidas entre -1 e 1


-1 → perfeita negativa

0 → sem relação

1 → perfeita positiva


Spearman

Usado em variáveis **contínuas** ou **ordinais**




↓

só sobe



↓

só desce




↓

sobe e desce

Pearson

Usado com variáveis quantitativas e é necessário uma distribuição normal.



Testes Paramétricos

Assumem dados sobre a população através de uma amostra. Assume que os dados são normalmente distribuídos.

São usados em variáveis quantitativas ou ordinais ≥ 7 níveis.

Testes Paramétricos

- One Sample T-Test
- Unpaired samples T-Test
- Paired samples T-Test
- One-way ANOVA

Antes de usar estes testes é necessário verificar os dados usando o teste de **Levene**. Este teste verifica a variância e se for diferente os testes paramétricos não vão ter bons resultados.

H₀ → Pode-se usar testes paramétricos

0,05 - → Usar testes não paramétricos

Student T-Test

Determina se a medida de um grupo e a população ou outro grupo difere.

One Sample → População x Grupo

Unpaired Independent Samples → Group x Group

Paired Samples → Same Group through time

One Sample T-Test

Verifica se a média da população é diferente de um número dado.

Two Tailed (diferença)

$H_0 \rightarrow$ A média é igual

$0,05 - \rightarrow$ A média não é igual

One Tailed (maior ou menor)

$H_0 \rightarrow$ A média é maior ou igual

$0,05 - \rightarrow$ A média é mais pequena

Unpaired Samples T-Test

Verifica se há diferença entre 2 grupos.

H_0 → As médias são iguais

Os grupos são da mesma população

$0,05 =$ → As médias são diferentes

Os grupos não são da mesma população

Paired Samples

Determina se há diferença entre 2 grupos durante o tempo. Exemplo tempo de estudo e notas para o 1º exame e o 2º.

H_0 → A média é a mesma.

$0,05$ → As médias são diferentes

ANOVA

Verifica se há diferença entre $2+$ grupos. A média e a variância é calculada em cada grupo. Pode ser usado com variáveis **nominais** ou **ordinais** como **independentes**. Usa **quantitativas** como **dependentes**.

Testes - Anova :

One Way → 1 variável independente

Two Way → 2 variáveis independentes

One way ANOVA

H_0 → A média é a mesma

$0,05$ - → A média é diferente

Alternativas	≠ variância → welch ANOVA
	≠ normal → kruskal-wallis

Post Hoc Tests

É usado para saber quais grupos diferem da média ou variância

Variância Igual

- Fisher
- Tukey
- Scheffe > 50+
- Newman Keuls
- Duncan
- Gabriel > Desequilibradas
- Hochberg
- Bonferroni > 12+
- REB W Q

Variação Diferente

- Dunnett's T3
- Dunnett's C
- Games Howell

One way ANOVA repeated

- o mesmo grupo é testado várias vezes. Por exemplo
- o peso todas as semanas durante 1 mês.

Testes não Paramétricos

Testes quando os dados não seguem uma distribuição normal, são melhores para amostras **pequenas**, a variável de estudo é melhor dada pela **Mediana**.

Testes	Wilcoxon
	Mann - Whitney
	Kruskal - Wallis

Rank (resultados dados nos testes)

Os dados são organizados ordenadamente e a sua posição é dada como o rank.

1 2 3 4 5,5 6
[1, 3, 4, 5, 6, 6, 7]

Wilcoxon

É a alternativa ^{não paramétrica} ao one-sample T-Test e paired t-Test.
Não assume que os grupos são normalmente distribuídos.

H_0 → Há diferença nas medianas

0,05 - → Não há diferença

Mann - Whitney

Alternativa não paramétrica ao unpaired t -student.

H_0 $\rightarrow$ Não há diferença no somatório de ranks

$0,05$ - $\rightarrow$ Existe diferença no somatório de ranks

Kruskal - Wallis

Alternativa não paramétrica ao one way anova. É usado para comparar vários grupos do mesmo tamanho.

H_0 $\rightarrow$ As médias de ranks são as mesmas

$0,05$ - $\rightarrow$ As médias são diferentes.

Inteligência Artificial

AI → Executa tarefas que necessitam de inteligência humana

Machine Learning → O computador aprende sozinho

Deep Learning → Algoritmos de redes neurais

Etapas da criação de um modelo

1. Coletar Dados
2. Limpar Dados
3. Escolher Algoritmo
4. Avaliar Algoritmo
5. Deploy


Tipos de Algoritmos

Supervised → Os dados de treino contêm as respostas corretas. Também chamados de **labels**, é um algoritmo de aprendizagem. **Prevê** o output.


Unsupervised → Sem labels. Self learning. Identifica *padrões*.

Não prevê output

Supervised learning



Unsupervised learning



Supervised learning

X_1	X_2	X_3	X_p	Y
				Duck
				Duck
				Not Duck
				Duck

Target

Unsupervised learning

X_1	X_2	X_3	X_p	Y

No Target

Tipos de Variáveis

Algoritmos
Classificação

Machine Learning


Supervisionadas		Não supervisionadas	
Regressão (numérica)	Linear	Clustering	Redução de Dimensionalidade
	Naïve Linear		
Classificação (categórica)	Decision Tree	k-Means	PCA
	Random Forest	DBSCAN	
	k-NN	Hierarchical Clustering	
	SVM		
	Naïve Bayes		
	Regressão logística		
	Accuracy		
	Precision		
	Sensibilidade (Recall)		
	Especificidade		
	F1-Score		
	AUC		

Supervised Learning

Atribui-se as variáveis independentes que juntas são atribuídas à **target** (variável dependente)


Regressão

Preve valores numéricos. Retorna um target numérico.




Classificação

Preve a categoria de um dado novo. Retorna um target categórico.



Regressão Linear

É feita uma reta de forma a que os valores sejam previstos por ela. É usado o MSE para verificar o quão bem a reta se adequa ao dataset.



$$\hat{y} = \theta_0 + \theta_1 x_1$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

θ_0 $\rightarrow$ grau


θ_1 $\rightarrow$ valor quando há interseção com o eixo

MSE $\rightarrow$ Média Residual de Erros

K N N

Agrupar dados em k clusters.

1. Escolher valor de k
2. Escolhe os k pontos mais próximos
3. Escolhe o grupo mais repetido dos k pontos

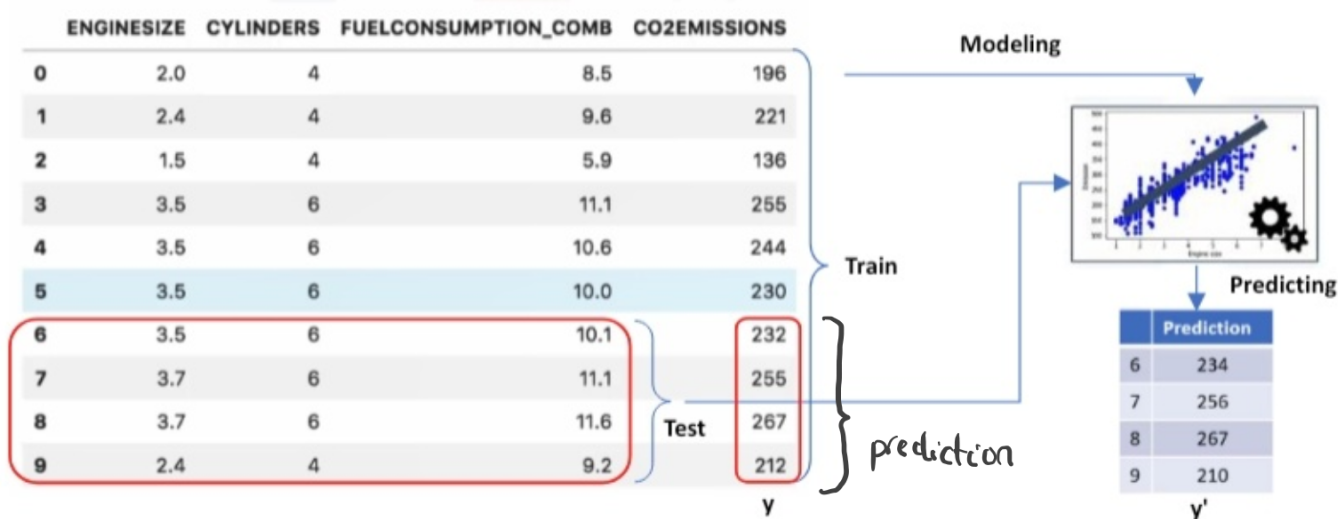


Medidas de Avaliação

- Train and Test no mesmo dataset
- Train / Test Split
- k-Fold Cross Validation


Train And Test

Primeiro treina-se com o dataset inteiro e depois podemos usar para prever um subset.



k- Fold

Divide o dataset em k vezes. Cada fold é usado para treinar o modelo e é feito a accuracy fazendo a média da accuracy de cada fold.



Avaliação de Regressão

$$MAE = \frac{\sum_i^N |y_i - \hat{y}_i|}{N}$$

Mean Absolute Error

→ Mean Absolute Error

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Mean Squared Error

→ Mean Squared Error

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{N}}$$

Root Mean Squared Error

→ Root Mean Squared Error

$$RAE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{\sum_{i=1}^n |y_i - \bar{y}|}$$

Relative Absolute Error

→ Relative Absolute Error

$$RSE = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Relative Squared Error

→ Relative Squared Error

$$R^2 = 1 - RSE$$

Avaliação de Classificação

Accuracy

Precision

Recall

F1 - Score

AUC

Accuracy

Ratio de valores corretos

$$\frac{TP + TN}{TP + TN + FP + FN} = \text{accuracy}$$

Precision

Número de previsões corretas

$$\frac{TP}{TP + FP} = \text{precision}$$

Recall (sensibilidade)

Ratio de casos realmente positivos

$$\frac{TP}{TP + FN} = \text{recall}$$

Specificity

Mede ratio de casos negativos verdadeiros

$$\frac{TN}{TN + FP} = \text{specificity}$$

F1 - Score

Combina precision e recall

$$\frac{(precision + recall)}{(precision + recall)} = F1 - score$$

AUC



Quanto menos sobre
mais perfeito é
o algoritmo.


Unsupervised Learning

2 tipos de learning:

- Clustering
- Redução de Dimensão (agrupar atributos)

Clustering

Deteta Padrões e junta os dados em grupos



Redução de Dimensão (Dimensionality Reduction)


Reduz a quantidade de atributos necessários

PCA -> Análise de Componentes Principais

PCA 1 -> Explica a máxima variância

PCA 2 -> Explica a restante máxima variância

Os componentes com menos variância são retirados



Python

- Anaconda
- Gestor de Pacotes Python
 - Multi Plataforma
 - Cria ambientes virtuais globalmente
 - instala as dependências compatíveis ao SO

Comandos

Gerir Pacotes

```
conda search search_term
conda install package_name
conda install numpy // installing numpy
conda install numpy=1.10 // installing numpy and its version
conda install numpy scipy pandas // installing multiple packages
conda remove package_name // remove a package
conda update package_name // update a package
conda update --all // update all packages in an environment
```

Generic Environments

<code>conda env list</code>	<code>// listing environments (* for current one)</code>
<code>conda create -n env_name list_packages</code>	<code>// creating an environment</code>
<code>conda create -n my_env numpy</code>	<code>// creating an environment</code>
<code>conda create -n py3 python=3</code>	<code>// specifying the python version</code>
<code>source activate my_env</code>	<code>// activate environment in Linux</code>
<code>activate my_env</code>	<code>// activate environment in Windows</code>
<code>source deactivate</code>	<code>// leave environment in Linux</code>
<code>deactivate</code>	<code>// leave environment in Windows</code>

Exporting Environments

<code>conda env export > environment.yaml</code>	<code>// exporting an environment</code>
<code>conda env create -f environment.yaml</code>	<code>// importing an environment</code>
<code>conda env remove -n env_name</code>	<code>// removing an environment</code>

Jupyter Notebooks

- É feito com **JSON**
- Formato **.ipynb**

Comandos Mágicos

!= comando bash

% → line magics

%s % → cell magics

%ls magic → lista os comandos mágicos

% matplotlib inline

%<% html → renderiza html diretamente no notebook